

ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ THÔNG TIN
KHOA KHOA HỌC MÁY TÍNH



BÁO CÁO ĐỒ ÁN CUỐI KỲ
MÔN HỌC XỬ LÝ NGÔN NGỮ TỰ NHIÊN

Đề tài:

**ĐÁNH GIÁ VÀ ĐỐI SÁNH HIỆU NĂNG CÁC KỸ
THUẬT N-GRAM KẾT HỢP MÔ HÌNH SUPPORT
VECTOR MACHINE CHO BÀI TOÁN PHÂN TÍCH
CẢM XÚC DỰA TRÊN PHẢN HỒI CỦA SINH VIÊN**

GVHD: Th.S Nguyễn Trọng Chính

Lớp: CS221.Q21

Nhóm sinh viên thực hiện:

- | | |
|---------------------|----------------|
| 1. Nguyễn Cao Cường | MSSV: 23520198 |
| 2. Nguyễn Quốc Đạt | MSSV: 23520260 |
| 3. Hà Hữu Trường An | MSSV: 24520042 |

[illegible]

(Ký tên và ghi rõ họ tên)

BẢNG PHÂN CÔNG, ĐÁNH GIÁ THÀNH VIÊN:*Bảng 1. Bảng phân công, đánh giá thành viên.*

Họ và tên	MSSV	Phân công	Đánh giá
Nguyễn Cao Cường	23520198	- Viết chương trình thu thập dữ liệu - Nghiên cứu, định hướng về việc gán nhãn dữ liệu thủ công và tự động - Đề xuất mô hình và thực hiện huấn luyện - Viết báo cáo chương 1 và 2	Hoàn thành tốt
Nguyễn Quốc Đạt	23520260	- Viết chương trình trích xuất dữ liệu - Hỗ trợ thực hiện gán nhãn thủ công cho mô hình - Viết đoạn chương trình huấn luyện mô hình và phân loại mô hình - Viết báo cáo chương 3 và 4	Hoàn thành tốt
Hà Hữu Trường An	24520042		Hoàn thành tốt

LỜI MỞ ĐẦU

Trong kỷ nguyên số hóa giáo dục, việc lắng nghe và thấu hiểu tâm tư, nguyện vọng của người học đóng vai trò then chốt trong việc nâng cao chất lượng đào tạo và cải thiện môi trường giảng dạy tại các trường đại học. Những phản hồi, ý kiến đóng góp của sinh viên sau mỗi học kỳ chính là nguồn dữ liệu vô giá. Tuy nhiên, việc xử lý thủ công khối lượng lớn văn bản này đòi hỏi rất nhiều thời gian và công sức. Chính vì vậy, bài toán phân tích cảm xúc đã trở thành một hướng nghiên cứu mang tính cấp thiết và có giá trị thực tiễn cao.

Báo cáo này tập trung vào đề tài “Đánh giá và đối sánh hiệu năng các kỹ thuật N-gram kết hợp mô hình Support Vector Machine cho bài toán phân tích cảm xúc dựa trên phản hồi của sinh viên”. Mục tiêu cốt lõi của đề tài là xây dựng một hệ thống phân loại sắc thái ý kiến dựa trên bộ ngữ liệu chuẩn UIT-VSFC, đồng thời tiến hành nghiên cứu thực nghiệm sâu sắc về tầm ảnh hưởng của các tầng không gian đặc trưng từ các kỹ thuật N-grams khi kết hợp cùng thuật toán Support Vector Machine (SVM).

Thông qua quá trình thực hiện đồ án, nhóm nghiên cứu không chỉ hiểu được quy trình xử lý ngôn ngữ tự nhiên từ bước tiền xử lý, trích xuất đặc trưng văn bản cho đến tối ưu hóa mô hình, mà còn hiểu sâu hơn về cách phân phối ngôn ngữ đặc thù trong môi trường học thuật. Đây là cơ hội quý báu giúp nhóm thực hiện củng cố vững chắc kiến thức, đồng thời tích lũy những kinh nghiệm thực tiễn quan trọng cho các nghiên cứu chuyên sâu hơn trong tương lai.

Sau đây, nhóm xin trình bày nội dung đồ án qua các chương:

- Chương 1: Giới thiệu đề tài
- Chương 2: Mô tả và phân tích bộ dữ liệu
- Chương 3: Quy trình và phương pháp thực hiện
- Chương 4: Mô hình huấn luyện và kết quả đánh giá
- Chương 5: Kết luận

LỜI CẢM ƠN

Lời đầu tiên, nhóm thực hiện xin dành gửi lời cảm ơn đến Th.S Nguyễn Trọng Chính vì đã giúp đỡ nhóm thực hiện trong việc hình thành ý tưởng cũng như giải đáp những điều khó hiểu trong quá trình thực hiện đồ án.

Do còn hạn chế về kiến thức cũng như kinh nghiệm thực hiện đề tài, đồ án chắc chắn không tránh khỏi những thiếu sót. Nhóm thực hiện rất mong nhận được những ý kiến đóng góp quý báu từ thầy để sản phẩm đồ án trở nên hoàn thiện hơn.

Xin trân trọng cảm ơn!

DANH MỤC CÁC BẢNG, HÌNH ẢNH

Danh mục các bảng:

Bảng 1. Bảng phân công, đánh giá thành viên.	3
Bảng 2. Kết quả tối ưu hóa siêu tham số trên không gian k-fold CV ($k = 5$)	28
Bảng 3. Bảng đối sánh hiệu năng tổng thể của mô hình SVM trên tập kiểm thử	29
Bảng 4. Bảng tổng hợp chi tiết hiệu năng phân loại theo từng nhãn của 6 cấu hình N-gram	30

Danh mục hình ảnh:

Hình 1. Biểu đồ phân bố số lượng câu cảm xúc theo từng tập dữ liệu con.....	15
Hình 2. Biểu đồ phân phối mật độ độ dài câu theo số lượng từ.....	15
Hình 3. Biểu đồ trực quan hóa quan hệ giữa hai nhãn tích cực và tiêu cực theo điểm TF-IDF	16
Hình 4. Biểu đồ Heatmap	28
Hình 5. Ma trận nhầm lẫn.....	30
Hình 6. Biểu đồ Learning Curves cho chỉ số Accuracy với các mô hình N-gram tương ứng.....	33
Hình 7. Biểu đồ Learning Curves cho chỉ số Macro F1-score với các mô hình N-gram tương ứng.....	33

MỤC LỤC

LỜI MỞ ĐẦU	4
LỜI CẢM ƠN	5
DANH MỤC CÁC BẢNG, HÌNH ẢNH.....	6
MỤC LỤC	7
CHƯƠNG 1: GIỚI THIỆU ĐỀ TÀI.....	9
1.1. Động lực nghiên cứu.....	9
1.2. Các thách thức của bài toán	9
1.2.1. Sự nhập nhằng của tiếng Việt	9
1.2.2. Tính đa dạng trong ngôn ngữ mạng.....	10
1.2.3. Sự bùng nổ số chiều vector và độ thưa của đặc trưng trong N -gram.....	10
1.3. Mục tiêu nghiên cứu	11
CHƯƠNG 2. MÔ TẢ BỘ DỮ LIỆU.....	13
2.1. Tổng quan bộ dữ liệu	13
2.2. Phân tích bộ dữ liệu	13
CHƯƠNG 3. PHƯƠNG PHÁP LUẬN.....	17
3.1. Các mô hình và thư viện được sử dụng.....	17
3.1.1. Mô hình N -grams	17
3.1.2. Chỉ số thống kê TF - IDF	18
3.1.3. Mối quan hệ giữa N -grams và chỉ số TF - IDF	19
3.1.4. Mô hình <i>Support Vector Machine</i>	20
3.1.5. Thư viện <i>underthesea</i>	21
3.2. Các chỉ số đánh giá mô hình.....	21
3.2.1. <i>Accuracy</i>	22
3.2.2. <i>Precision</i>	23
3.2.3. <i>Recall</i>	24
3.2.4. <i>F1-Score</i>	24
CHƯƠNG 4. CÀI ĐẶT MÔ HÌNH VÀ KẾT QUẢ ĐÁNH GIÁ.....	26
4.1. Cài đặt mô hình	26
4.1.1. Môi trường thực nghiệm và hệ thống thư viện phần mềm.....	26
4.1.2. Thiết lập cấu trúc Pipeline và không gian siêu tham số.....	26
4.1.3. Chiến lược tối ưu hóa tham số và phương pháp đánh giá mô hình.....	27
4.2. Kết quả huấn luyện	27

4.2.1. Kết quả tối ưu hóa siêu tham số (Grid Search Heatmap Analysis)	27
4.2.2. Kết quả phân loại tổng thể và đối sánh hiệu năng trên tập kiểm thử (Test Set)	28
4.2.3. Phân tích cụ thể từng lớp và ma trận nhầm lẫn	29
4.2.3.1. Nhóm 1 - Các mô hình tích hợp đặc trưng từ đơn	31
4.2.3.2. Nhóm 2 - Các mô hình thuần bậc cao và tổ hợp bậc cao thiếu Unigram	31
4.2.4. Khảo sát biến động đường học (Learning Curves)	32
4.2.4.1. Tốc độ học ẩn tượng ở giai đoạn đầu	33
4.2.4.2. Hiện tượng bão hòa hiệu năng và giới hạn tiệm cận phẳng	34
4.2.4.3. Mối quan hệ giữa Bias - Variance và cấu trúc chiều không gian vector	34
Chương 5. KẾT LUẬN	36
4.1. Ưu điểm	36
4.2. Nhược điểm	36
4.3. Hướng phát triển	37
TÀI LIỆU THAM KHẢO	38
PHỤ LỤC	39

CHƯƠNG 1: GIỚI THIỆU ĐỀ TÀI

1.1. Động lực nghiên cứu

Trong thời đại kỷ nguyên số hóa giáo dục, việc duy trì và nâng cao chất lượng đào tạo là mục tiêu chiến lược và cấp thiết của các cơ sở giáo dục. Một trong những kênh thông tin khách quan và giá trị nhất để đánh giá hiệu quả giảng dạy chính là dữ liệu phản hồi của sinh viên sau mỗi học kỳ. Các ý kiến đóng góp này chứa đựng những góc nhìn chân thực về phương pháp sư phạm của giảng viên, nội dung cấu trúc môn học, cũng như điều kiện cơ sở vật chất của nhà trường. Từ đó thúc đẩy động lực giúp nhà trường và giảng viên có cơ sở để nhìn nhận, đánh giá và cải thiện chất lượng giáo dục.

Tuy nhiên, với quy mô đào tạo lên đến hàng chục nghìn sinh viên tại các trường đại học, số lượng phản hồi thu thập được sau mỗi kỳ học là cực kỳ lớn. Việc xử lý, phân loại và tổng hợp các phản hồi này bằng phương pháp thủ công khiến cho nhà trường phải đối mặt với nhiều hạn chế nghiêm trọng như tốn kém nguồn nhân sự, tốn kém thời gian tổng hợp và phân nào làm giảm đi tính khách quan trong quá trình đánh giá.

Sự phát triển của Xử lý ngôn ngữ tự nhiên và Học máy đã mở ra giải pháp tự động hóa quy trình này thông qua bài toán phân tích cảm xúc. Trong đó, mô hình Support Vector Machine (SVM) từ lâu đã khẳng định được tính hiệu quả, độ ổn định và khả năng phân lớp vượt trội trên các vùng dữ liệu có số chiều lớn. Tuy nhiên, hiệu năng của SVM phụ thuộc rất lớn vào cách thức trích xuất và biểu diễn đặc trưng văn bản. Kỹ thuật N-gram vốn được xem là một phương pháp tiếp cận kinh điển nhưng mạnh mẽ, cho phép mô hình thu giữ các thông tin ngữ cảnh cục bộ bằng cách cấu hình các từ đơn lẻ hoặc cụm từ liên kề.

Xuất phát từ nhu cầu thực tiễn của công tác quản lý giáo dục và mong muốn tìm hiểu sâu sắc cấu hình tối ưu cho bài toán phân loại văn bản tiếng Việt đặc thù, nhóm thực hiện đã quyết định chọn đề tài: "Đánh giá và đối sánh hiệu năng các kỹ thuật N-gram kết hợp mô hình Support Vector Machine cho bài toán phân tích cảm xúc dựa trên phản hồi của sinh viên".

1.2. Các thách thức của bài toán

1.2.1. Sự nhập nhằng của tiếng Việt

Không giống như các ngôn ngữ phương Tây như tiếng Anh hoặc tiếng Pháp vốn sử dụng khoảng trắng làm ranh giới phân tách từ rõ ràng, tiếng Việt là ngôn ngữ đơn

lập¹ mang tính phân tiết² cao. Đặc trưng này dẫn đến việc khoảng trắng trong văn bản tiếng Việt chỉ đóng vai trò phân tách các âm tiết (tiếng) cấu thành, chứ không phải là ranh giới phân tách các từ (bao gồm từ đơn, từ ghép, từ láy). Do đó, nếu bộ trích xuất N-gram hoạt động trực tiếp trên tầng âm tiết thô mà không thông qua bước tách từ chuẩn xác mô hình SVM sẽ bị nhiễu do mất đi ngữ nghĩa gốc của từ ghép.

Ví dụ: Cụm từ "học sinh học sinh học" có thể gây nhập nhằng rất lớn cho bộ tách từ vì nó có thể là "học_sinh học sinh_học" hoặc "học_sinh học_sinh học".

1.2.2. Tính đa dạng trong ngôn ngữ mạng

Dữ liệu phản hồi của sinh viên thuộc loại văn bản ngắn, phi chính thức và chứa đựng rất nhiều biến thể nhiễu của ngôn ngữ mạng (Teencode), cụ thể:

- *Sự đa dạng về từ viết tắt và lỗi chính tả:* Sinh viên thường viết tắt theo thói quen (Ví dụ: gv - giảng viên, ko/k - không, dc/đc - được) hoặc sử dụng các từ biến thể (rùi thay vì rồi, bunn thay vì buồn, khum/hum thay vì không).
- *Cấu trúc phủ định và đảo ngữ phức tạp:* Sắc thái của câu thay đổi hoàn toàn khi có sự xuất hiện của các từ phủ định như *không*, *chưa*,... Nếu chỉ sử dụng Unigram, mô hình SVM hoàn toàn bất lực trong việc phân biệt sắc thái giữa hai câu *thầy dạy không hay* và *thầy dạy không thể nào hay hơn do bản chất túi từ (Bag-of-Words) đã làm mất đi sự liên kết của từ phủ định*.
- *Hiện tượng đa sắc thái và mỉa mai trong văn nói:* Nhiều phản hồi mang tính nghị luận hoặc sử dụng câu hỏi tu từ, khen ngợi ở vế đầu nhưng chê trách ở vế sau, gây khó khăn lớn cho việc xác định biên phân lớp của SVM. (Ví dụ: "mong được làm việc với thầy nhiều hơn" có thể hiểu là *sinh viên mong muốn được có thêm cơ hội học hỏi từ giảng viên* hoặc cũng có thể hiểu là *giảng viên không có nhiều tính tương tác với sinh viên trong quá trình giảng dạy*)

1.2.3. Sự bùng nổ số chiều vector và độ thưa của đặc trưng trong N-gram

Khi tăng giá trị N từ Unigram lên Bigram và Trigram để bắt giữ ngữ cảnh dài hơn, không gian đặc trưng sẽ bùng nổ theo cấp số nhân. Sự bùng nổ này tạo ra các ma trận đặc trưng vô cùng thưa thớt nơi phần lớn các giá trị trong vector biểu diễn bằng 0.

Mặc dù SVM là thuật toán xử lý tốt dữ liệu nhiều chiều, việc đối mặt với một ma trận quá thưa và chứa nhiều cụm N-gram hiếm gặp (nhiều) có thể dẫn đến hiện tượng

¹ Ngôn ngữ đơn lập (hay ngôn ngữ đơn tiết/không biến hình) là loại hình ngôn ngữ trong đó từ không thay đổi hình thái (không chia thì, số, giống, cách)

² Ngôn ngữ phân tiết tính (phân tiết) là loại hình ngôn ngữ mà mỗi âm tiết được phát âm tách bạch, rõ ràng và có tính độc lập cao.

quá khớp (Overfitting), làm giảm khả năng tổng quát hóa của mô hình và tăng chi phí tính toán của bộ nhớ một cách đáng kể.

1.3. Mục tiêu nghiên cứu

Xây dựng quy trình tiền xử lý văn bản tiếng Việt tối ưu cho dữ liệu sinh viên bằng cách thực hiện các kỹ thuật chuẩn hóa teencode, sửa lỗi chính tả, tách từ tiếng Việt, và loại bỏ stopwords phù hợp nhằm giảm nhiễu tối đa trước khi đưa vào bộ trích xuất đặc trưng.

Hiện thực hóa và tích hợp các bộ trích xuất đặc trưng N-gram với 03 không gian đặc trưng riêng biệt bao gồm: Unigram, Bigram, Trigram và các dạng kết hợp dựa trên mô hình tần suất TF-IDF.

Huấn luyện và tối ưu hóa mô hình Support Vector Machine (SVM) bằng cách thực hiện tìm kiếm thực nghiệm các siêu tham số tối ưu (như hàm nhân - Kernel: Tuyến tính, RBF; tham số phạt C) cho SVM tương ứng với từng loại đặc trưng N-gram.

Đánh giá và đối sánh thực nghiệm toàn diện bằng cách đo lường, so sánh phân tích định lượng hiệu năng phân lớp cảm xúc của các mô hình thông qua hệ thống chỉ số chuẩn mực bao gồm Accuracy, Precision, Recall và F1-score. Từ kết quả đối sánh, ta có thể rút ra kết luận về việc liệu mức độ mở rộng ngữ cảnh của N-gram có thực sự giúp cải thiện độ chính xác của mô hình SVM đối với loại văn bản phản hồi ngắn của sinh viên hay không.

1.4. Mô hình hóa bài toán

- *Input*: Tập dữ liệu $D = \{x_1, x_2, \dots, x_N\}$ gồm N câu phản hồi thô của sinh viên dưới dạng chuỗi ký tự tự do bằng tiếng Việt. Trong đó, mỗi câu văn $x_i \in X$ ban đầu chứa nhiều biến thể nhiễu của ngôn ngữ mạng (Teencode), lỗi chính tả và cấu trúc từ phức chưa được xử lý chuẩn hóa.

- *Output*: Một tập các nhãn cảm xúc $Y = \{y_1, y_2, \dots, y_N\}$ tương ứng của tập dữ liệu D . Ứng với mỗi câu phản hồi x_i , nhãn y_i sẽ nhận một trong ba giá trị thuộc tập nhãn mục tiêu $y_i \in \mathcal{C} = \{0, 1, 2\}$ với 0, 1, 2 lần lượt biểu thị sắc thái tiêu cực, trung tính và tích cực.

- *Mục tiêu*: Tìm kiếm một hàm quyết định tối ưu f thực hiện ánh xạ từ không gian văn bản sang không gian nhãn $f: D \rightarrow \mathcal{C}$ với tập dữ liệu huấn luyện $D_{train} = \{(x_i, y_i)\}_{i=1}^M$. Hiệu năng của hàm f được đánh giá độc lập trên tập dữ liệu kiểm thử D_{test} sau khi hàm f được xây dựng dựa trên hai giai đoạn:

- *Giai đoạn trích xuất đặc trưng văn bản:* Ánh xạ chuỗi ký tự tự do x_i thành một vector đặc trưng số thực cao chiều $\mathbf{x}_i \in \mathbb{R}^d$ dựa trên mô hình N-gram ($N = 1, 2, 3$) và mô hình TF-IDF.
- *Giai đoạn tối ưu hóa phân lớp:* Sử dụng thuật toán Soft-margin Support Vector Machine để xác định siêu phẳng phân hoạch $w^T x + b = 0$ trong không gian $\mathbb{R}^d$ sao cho tối thiểu hóa hàm mất mát và tối đa hóa biên phân lớp giữa các Support Vectors của các nhãn.

CHƯƠNG 2. MÔ TẢ BỘ DỮ LIỆU

2.1. Tổng quan bộ dữ liệu

Nhóm thực hiện sử dụng bộ dữ liệu UIT-VSFC để phục vụ cho đề tài này. Ngữ liệu được trích xuất trực tiếp từ hệ thống khảo sát trực tuyến về chất lượng hoạt động giảng dạy, môn học và cơ sở vật chất. Đối tượng tham gia khảo sát là sinh viên chính quy thuộc nhiều khóa và nhiều ngành học khác nhau tại trường từ năm 2013 đến năm 2016, đảm bảo tính đa dạng trong cách hành văn và từ vựng.

Bộ dữ liệu đã được nhóm tác giả chia làm 03 tập dữ liệu con gồm tập Test, tập Validation và tập Train. Mỗi tập gồm 03 cột và số dòng tương ứng với số lượng dữ liệu được mô tả trong bảng 2, trong đó có 02 biến số và 01 biến phân loại. Cụ thể như sau:

Bảng 2. Cấu trúc và thuộc tính các trường thông tin trong bộ ngữ liệu UIT-VSFC

STT	Tên cột	Kiểu dữ liệu	Giải thích
1	sentence	string	Lưu trữ nội dung văn bản thô của câu phản hồi. Đây là các câu văn ngắn hoặc trung bình, thể hiện trực tiếp quan điểm của sinh viên về một khía cạnh cụ thể.
2	sentiment	int64	Lưu trữ nhãn mục tiêu của bài toán phân lớp, nhận một trong ba giá trị 0, 1, 2 tương ứng với 04 phân lớp sắc thái cảm xúc độc lập lẫn lượt là tiêu cực (negative), trung lập (neutral) và tích cực (positive).
3	topic	int	Lưu trữ nhãn mục tiêu của bài toán phân lớp, nhận một trong bốn giá trị 0, 1, 2, 3 tương ứng với 04 phân lớp chủ đề độc lập lẫn lượt là giảng viên (lecturer), chương trình đào tạo (training_program), cơ sở vật chất (facility) và khác (others)

Bảng 3. Bảng phân bố tập dữ liệu UIT-VSFC trên các tập dữ liệu con

Tập	Tiêu cực	Trung lập	Tích cực	Tổng cộng
Train	5325	458	5643	11426
Validation	705	73	805	1583
Test	1409	167	1590	3166
Tổng cộng	7439	698	8038	16175

2.2. Phân tích bộ dữ liệu

Vì mục đích của đề tài hướng đến bài toán phân tích cảm xúc, do đó nhóm thực hiện không tiến hành phân tích và thực hiện loại bỏ cột *topic* (chủ đề) cho đề tài này.


Dựa vào cột *sentiment* (*sắc thái*) của bộ dữ liệu, ta có thể thấy mỗi câu được gán nhãn bằng một trong ba nhãn gồm tích cực, tiêu cực và trung lập. Cụ thể:

- *Nhãn tích cực*: Thể hiện sắc thái hài lòng, khen ngợi, đồng tình hoặc biết ơn đối với bài giảng, giảng viên hoặc nhà trường. (Ví dụ: Giảng viên cho bài tập sát với nội dung, giảng giải dễ hiểu.)
- *Nhãn tiêu cực*: Thể hiện sắc thái không hài lòng, phê bình, phàn nàn hoặc góp ý về các điểm hạn chế, bất cập cần khắc phục. (Ví dụ: Giảng không tận tình, chỉ ngồi một chỗ và nói và đọc slide.)
- *Nhãn trung lập*: Mang tính liệt kê, mô tả sự kiện mang tính khách quan, hoặc chứa cả ý khen lẫn chê tương đương nhau, không rõ xu hướng sắc thái. (Ví dụ: Có cung cấp tài liệu cho sinh viên.)

Bảng 4. Ví dụ các mẫu câu thuộc các nhãn tương ứng trong bộ dữ liệu


STT	Câu	Nhãn
1	Slide bài giảng đầy đủ rõ ràng, giáo viên đúng giờ, giảng giải tận tình, luôn giúp đỡ sinh viên về vấn đề bài học.	Tích cực (2)
2	Nhưng nguyên nhân chán có lẽ vì không hiểu được mục đích môn học sau khi học xong nên không muốn học.	Tiêu cực (0)
3	Có cung cấp tài liệu cho sinh viên.	Trung lập (1)

Biểu đồ *Hình 1* thể hiện phân phối ba nhãn cảm xúc Tiêu cực, Trung lập và Tích cực trên ba tập Train, Validation và Test. Kết hợp với số liệu ở *Bảng 2*, có thể thấy phân phối nhãn giữa ba tập dữ liệu tương đối nhất quán: hai lớp Tiêu cực và Tích cực chiếm đa số, trong khi lớp Trung lập có số lượng thấp hơn rất nhiều. Điều này lại vô tình khiến cho mô hình khó học được các đặc trưng của nhãn Tiêu cực, dẫn đến các chỉ số đánh giá cho tập này có thể rất thấp. Tuy nhiên, biểu đồ phân phối giữa các nhãn có xu hướng tương tự nhau lại giúp cho quá trình chia dữ liệu tương đối ổn định, không tạo ra hiện tượng một tập nào đó bị lệch phân phối quá mạnh, từ đó kết quả đánh giá cuối cùng sẽ trở nên đáng tin cậy hơn rất nhiều.



Hình 1. Biểu đồ phân bố số lượng câu cảm xúc theo từng tập dữ liệu con


Biểu đồ Hình 2 thể hiện phân phối độ dài câu theo số lượng từ. Phân phối có dạng lệch phải, tức phần lớn câu có độ dài ngắn hoặc trung bình, trong khi chỉ có một số ít câu rất dài tạo thành phần đuôi kéo dài về bên phải. Dễ thấy, vì trung bình độ dài câu là khoảng 14.2 từ, trong khi trung vị là 11.0 từ, nên ta có thể kết luận phân phối độ dài câu bị kéo lệch bởi một nhóm nhỏ các câu dài bất thường. Đây là đặc điểm thường gặp trong dữ liệu phản hồi sinh viên: đa số phản hồi ngắn, trực tiếp, nhưng vẫn tồn tại một số phản hồi dài do người viết trình bày thêm lý do, bối cảnh hoặc đề xuất cải thiện.



Hình 2. Biểu đồ phân phối mật độ độ dài câu theo số lượng từ

Biểu đồ Hình 3 thực hiện trực quan hóa quan hệ giữa hai nhãn tích cực và tiêu cực theo điểm TF-IDF. Quan sát biểu đồ cho thấy có một số vùng phân tách tương đối rõ. Nhiều điểm màu xanh lá nằm gần trục tung, tức điểm TF-IDF tiêu cực gần bằng 0 nhưng điểm TF-IDF tích cực cao. Đây là những câu có nhiều từ khóa tích cực và ít hoặc không có từ khóa tiêu cực. Ngược lại, nhiều điểm màu đỏ tập trung ở vùng gần trục hoành, thể hiện các câu có tín hiệu tiêu cực mạnh hơn tín hiệu tích cực.

Tuy nhiên, biểu đồ cũng cho thấy một vùng chồng lấn lớn giữa hai lớp, đặc biệt ở khu vực điểm TF-IDF từ thấp đến trung bình. Điều này rất quan trọng về mặt phân tích mô hình. Nếu hai lớp có thể tách biệt tuyến tính hoàn toàn, phần lớn điểm xanh sẽ nằm rõ phía trên đường cân bằng và phần lớn điểm đỏ sẽ nằm rõ phía dưới. Nhưng trong biểu đồ này, hai lớp vẫn đan xen đáng kể. Điều đó cho thấy phân loại cảm xúc không thể chỉ dựa vào một vài nhóm từ khóa đơn giản mà nó còn phụ thuộc rất nhiều vào ngữ cảnh, cấu trúc phủ định và mức độ pha trộn giữa các sắc thái cảm xúc.



Hình 3. Biểu đồ trực quan hóa quan hệ giữa hai nhãn tích cực và tiêu cực theo điểm TF-IDF

CHƯƠNG 3. PHƯƠNG PHÁP LUẬN

3.1. Các mô hình và thư viện được sử dụng

3.1.1. Mô hình N-grams

Giả sử một chuỗi văn bản gồm n từ được biểu diễn dưới dạng một chuỗi các biến ngẫu nhiên $w_{1:n} = (w_1, w_2, \dots, w_n)$. Theo quy tắc chuỗi trong xác suất, xác suất đồng thời của toàn bộ chuỗi văn bản được tách thành tích của các xác suất điều kiện thành phần:

$$P(w_{1:n}) = P(w_1)P(w_2 | w_1)P(w_3 | w_{1:2}) \dots P(w_n | w_{1:n-1}) = \prod_{k=1}^n P(w_k | w_{1:k-1})$$

Tuy nhiên, việc tính toán chính xác xác suất điều kiện của một từ dựa trên toàn bộ lịch sử phía trước $P(w_n | w_{1:n-1})$ gặp phải thách thức lớn về mặt tính toán và phân tán dữ liệu, do ngôn ngữ có tính sáng tạo và nhiều chuỗi ngữ cảnh dài chưa từng xuất hiện trong tập huấn luyện.

Để giải quyết giới hạn này, giả thuyết Markov đã được sử dụng với phát biểu như nhau: xác suất xuất hiện của một từ tương lai có thể được dự đoán mà không cần nhìn quá xa về quá khứ, mà chỉ phụ thuộc vào một cửa sổ cố định gồm $N-1$ từ liền kề trước đó. Công thức xấp xỉ tổng quát cho mô hình N-gram được định nghĩa như sau:

$$P(w_n | w_{1:n-1}) \approx P(w_n | w_{n-N+1:n-1})$$

- Khi $N = 2$ (Bigram), xác suất của từ hiện tại chỉ phụ thuộc vào một từ ngay trước nó: $P(w_n | w_{1:n-1}) \approx P(w_n | w_{n-1})$
- Khi $N = 3$ (Mô hình Trigram): Xác suất phụ thuộc vào hai từ trước đó.

Các tham số xác suất của mô hình N-gram được ước lượng thông qua phương pháp ước lượng hợp lý cực đại (Maximum Likelihood Estimation - MLE) bằng cách đếm tần suất xuất hiện của các chuỗi từ trong ngữ liệu huấn luyện và chuẩn hóa chúng về khoảng $[0, 1]$:

$$P_{MLE}(w_n | w_{n-N+1:n-1}) = \frac{C(w_{n-N+1:n-1}w_n)}{C(w_{n-N+1:n-1})}$$

Trong đó, $C(w_{n-N+1:n-1}w_n)$ là tần suất xuất hiện của chuỗi N từ trong ngữ liệu, và $C(w_{n-N+1:n-1})$ là tần suất xuất hiện của chuỗi tiền tố (prefix) gồm $N-1$ từ.

Trong bài toán phân tích cảm xúc từ ý kiến sinh viên, các cấu trúc đảo ngữ hoặc phủ định mang tính quyết định đến sắc thái biểu cảm (ví dụ *không thích*, *rất hài lòng*). Nếu chỉ sử dụng các từ đơn lẻ (Unigram), mô hình sẽ hoàn toàn làm mất đi tính liên kết ngữ cảnh cục bộ này. Việc áp dụng mô hình N-grams như là Bigram và Trigram giúp

đề tài thu giữ được các cụm từ biểu thị trạng thái cảm xúc toàn vẹn, từ đó nâng cao độ chính xác trong việc phân loại các nhãn cảm xúc tích cực, tiêu cực hoặc trung tính.

3.1.2. Chỉ số thống kê TF-IDF

Chỉ số TF-IDF (Term Frequency - Inverse Document Frequency) là một phương pháp trọng số thống kê được sử dụng để đánh giá mức độ quan trọng của một từ (hoặc một đặc trưng đại diện) đối với một văn bản trong một tập hợp ngữ liệu. Trọng số này là tích của hai thành phần độc lập: tần suất xuất hiện của từ (TF) và nghịch đảo tần suất văn bản (IDF).

- *Tần suất xuất hiện của từ (Term Frequency - $tf_{t,d}$):* Thành phần này đo lường mức độ thường xuyên xảy ra của thuật ngữ t trong văn bản d . Nhằm giảm thiểu tác động của việc một thuật ngữ xuất hiện quá nhiều lần làm sai lệch độ liên quan ngữ nghĩa (vì một từ xuất hiện 100 lần không có nghĩa là nó quan trọng gấp 100 lần), hàm logarit cơ số 10 được áp dụng để làm mượt giá trị:

$$tf_{t,d} = \begin{cases} 1 + \log_{10} count(t,d) & \text{if } count(t,d) > 0 \\ 0 & \text{if } count(t,d) \leq 0 \end{cases}$$

Trong đó $count(t,d)$ là số lần xuất hiện thô của thuật ngữ t trong văn bản d .

- *Nghịch đảo tần suất văn bản (Inverse Document Frequency - idf_t):* Thành phần này đo lường mức độ phổ biến mang tính hệ thống của thuật ngữ t trên toàn bộ tập ngữ liệu D . Các thuật ngữ xuất hiện ở hầu hết các văn bản thường mang ít thông tin đặc trưng để phân biệt. Công thức tính idf_t được xác định bởi:

$$idf_t = \log_{10} \frac{N}{df_t}$$

Trong đó N là tổng số lượng văn bản có trong tập ngữ liệu và df_t là số lượng văn bản chứa thuật ngữ t . Thuật ngữ xuất hiện càng ít văn bản thì trọng số idf_t càng lớn; ngược lại, thuật ngữ xuất hiện trong mọi văn bản sẽ nhận trọng số bằng 0.

- *Trọng số tổng hợp TF-IDF ($tf-idf(t,d)$):* Trọng số cuối cùng của thuật ngữ t trong văn bản d là tích số của hai thành phần trên:

$$tf-idf(t,d) = tf_{t,d} \times idf_t$$

Khi biểu diễn dưới không gian vector, độ tương đồng giữa hai văn bản (hoặc giữa câu truy vấn và văn bản) thường được tính toán thông qua hàm độ tương đồng Cosine, bản chất là tích vô hướng của các vector đặc trưng sau khi đã chuẩn hóa về vector đơn vị:

$$score(q, d) = \cos(q, d) = \frac{\sum_{t \in q} tf-idf(t, q) \cdot tf-idf(t, d)}{\sqrt{\sum_{q_i \in q} tf-idf^2(q_i, q)} \cdot \sqrt{\sum_{d_i \in d} tf-idf^2(d_i, d)}}$$

Trong tập dữ liệu phản hồi của sinh viên, tồn tại rất nhiều từ ngữ mang tính hành chính hoặc học thuật chung xuất hiện với tần suất dày đặc trong mọi văn bản (ví dụ: *giảng viên, môn học, sinh viên, thầy, cô*) các từ này không mang giá trị phân loại thái độ cảm xúc. Chỉ số TF-IDF đóng vai trò sàng lọc tự động bằng cách hạ thấp trọng số của các từ chung chung này (IDF thấp) và nâng cao trọng số của các từ mang tính biểu cảm đặc trưng chỉ xuất hiện cục bộ trong một số phản hồi nhất định (IDF cao), giúp mô hình tập trung vào các đặc trưng sinh trị cảm xúc mạnh.

3.1.3. Mối quan hệ giữa N-grams và chỉ số TF-IDF

Trong cách tiếp cận truyền thống, chỉ số TF-IDF được tính toán dựa trên cấu trúc túi từ (Bag-of-Words), trong đó thuật ngữ t được định nghĩa cố định là một từ đơn lẻ (Unigram). Khi tích hợp mô hình N-grams vào TF-IDF, khái niệm thuật ngữ t được mở rộng từ một từ đơn thành một chuỗi liên tục gồm N từ: $t = w_{k-N+1:k}$. Khi đó, các công thức toán học của TF-IDF được điều chỉnh tương ứng:

- $count(t, d)$ chuyển thành tần suất xuất hiện của chuỗi phối hợp N-gram trong văn bản d .
- df_t chuyển thành số lượng văn bản trong toàn bộ ngữ liệu có chứa chuỗi N-gram đó.

Sự kết hợp này tạo ra một không gian vector đặc trưng mới có số chiều lớn hơn và thưa hơn (sparse matrix), nhưng giữ được cấu trúc cú pháp nguyên bản của văn bản, giúp giải quyết triệt để điểm yếu lớn nhất của mô hình túi từ truyền thống là bỏ qua thứ tự từ. Đối với ngữ liệu UIT-VSFC, việc định lượng hóa một chuỗi bằng TF-IDF dưới dạng một đặc trưng thống nhất ($N = 2$) sẽ mang lại giá trị phân loại chính xác hơn nhiều so với việc tách rời thành hai từ (ví dụ như *không nhiệt tình* sẽ bị tách thành *không* và *nhiệt_tình*) vốn sẽ khiến bộ phân lớp nhận diện nhầm lẫn giữa hai sắc thái đối lập nhau hoàn toàn.

3.1.4. Mô hình Support Vector Machine

Mô hình Support Vector Machine (SVM) là một thuật toán học có giám sát mạnh mẽ thuộc lớp các mô hình tuyến tính, được tối ưu hóa cho bài toán phân loại nhị phân hoặc đa lớp dữ liệu. Ý tưởng cốt lõi của SVM là tìm kiếm một siêu phẳng phân hoạch tối ưu trong không gian đặc trưng đa chiều để phân tách các điểm dữ liệu thuộc các lớp khác nhau, sao cho khoảng cách từ các điểm dữ liệu gần nhất của các lớp (gọi là các Support Vectors) đến siêu phẳng này là cực đại.

Giả sử tập dữ liệu huấn luyện có dạng: $D = \{(x_i, y_i)\}_{i=1}^m$, trong đó $x_i \in \mathbb{R}^d$ là vector đặc trưng biểu diễn văn bản (ở đây là vector TF-IDF của N-grams) và $y_i \in \{-1, 1\}$ là nhãn cảm xúc tương ứng. Siêu phẳng phân hoạch có phương trình dạng:

$$w^T x + b = 0$$

Trong đó $w \in \mathbb{R}^d$ là vector pháp tuyến của siêu phẳng và $b \in \mathbb{R}$ là hệ số tự do.

Khoảng cách hình học từ một điểm đến siêu phẳng được cực đại hóa bằng cách giải bài toán tối ưu hóa ràng buộc hình thức sau:

$$\min_{w,b} \frac{1}{2} \|w\|^2 \text{ thỏa mãn } y_i(w^T x_i + b) \geq 1, \forall i = 1, \dots, m$$

Trong thực tế, do dữ liệu văn bản thường không phân tách tuyến tính một cách tuyệt đối, mô hình SVM biên mềm (Soft-margin SVM) được áp dụng bằng cách bổ sung biến bù nhin (slack variables) $\xi_i \geq 0$ và tham số phạt C để cân bằng giữa việc cực đại hóa biên và thiểu số hóa sai số huấn luyện:

$$\min_{w,b,\xi} \frac{1}{2} \|w\|^2 + C \sum_{i=1}^m \xi_i \text{ thỏa mãn } y_i(w^T x_i + b) \geq 1 - \xi_i, \xi_i \geq 0$$

Đối với các cấu trúc phân tách phi tuyến phức tạp hơn, SVM sử dụng phương pháp ánh xạ dữ liệu vào không gian có số chiều cao hơn thông qua hàm nhân toán học (Kernel Trick) như Kernel tuyến tính, Kernel đa thức, hoặc RBF (Radial Basis Function).

Xét bộ dữ liệu UIT-VSFC, không gian đặc trưng tạo ra từ sự kết hợp giữa N-grams và TF-IDF trên ngữ liệu chữ viết thường có số chiều cực kỳ lớn (lên tới hàng chục nghìn chiều) nhưng lại có độ thưa cao. SVM đặc biệt hiệu quả và có khả năng chống quá khớp (overfitting) rất tốt trong các không gian cao chiều này do ranh giới quyết định của nó chỉ phụ thuộc vào các vector hỗ trợ thay vì toàn bộ các điểm dữ liệu. Do đó, SVM là bộ phân lớp lý tưởng nhằm tối ưu hóa độ chính xác và tốc độ hội tụ khi huấn luyện mô hình phân tích cảm xúc sinh viên.

3.1.5. Thư viện *underthesea*

underthesea là một thư viện mã nguồn mở chuyên biệt cho các tác vụ xử lý ngôn ngữ tự nhiên dành riêng cho tiếng Việt. Thư viện này tích hợp các mô hình học máy tiên tiến để giải quyết các đặc thù ngôn ngữ học của tiếng Việt.

Khác với tiếng Anh hay các ngôn ngữ phương Tây sử dụng khoảng trắng làm ranh giới phân tách từ (word tokenization), tiếng Việt là một ngôn ngữ đơn lập, âm tiết tính. Khoảng trắng trong tiếng Việt vừa được dùng để phân tách các âm tiết trong một từ phức, vừa dùng để phân tách các từ độc lập với nhau. Ví dụ, chuỗi *sinh viên* gồm hai âm tiết nhưng chỉ cấu thành một từ mang một đơn vị ngữ nghĩa duy nhất.

Thư viện *underthesea* cung cấp hàm cốt lõi về tách từ tiếng Việt, thực hiện ánh xạ chuỗi ký tự thô đầu vào S thành một danh sách các từ có nghĩa $f_{\text{seg}}(S) = [w_1, w_2, \dots, w_k]$ dựa trên các mô hình chuỗi ký tự kết hợp từ điển toán học.

Có thể thấy, bước tách từ là tiền đề bắt buộc và quan trọng nhất trong toàn bộ quy trình xử lý. Nếu không sử dụng *underthesea* để thực hiện gom cụm từ phức chính xác, mô hình N-grams ở bước sau sẽ nhận diện sai lệch trầm trọng (ví dụ: chuỗi *học tập* bị tách thành hai unigram rời rạc là *học* và *tập*, dẫn đến việc sinh các bigram vô nghĩa). Việc ứng dụng thư viện giúp chuẩn hóa dữ liệu phản hồi của sinh viên về đúng đơn vị từ vựng tiếng Việt chuẩn, làm cơ sở vững chắc cho việc trích xuất đặc trưng TF-IDF chính xác ở các bước tiếp theo.

3.2. Các chỉ số đánh giá mô hình

Trong các nghiên cứu về học máy và xử lý ngôn ngữ tự nhiên, việc định lượng hóa hiệu năng của các mô hình phân lớp đóng vai trò quyết định để chứng minh tính thực tiễn của phương pháp luận. Trước khi thiết lập các công thức toán học cho từng chỉ số, một Ma trận nhầm lẫn (Confusion Matrix) tổng quát cần được xây dựng để làm cơ sở dữ liệu nền tảng.

Đối với bài toán phân loại nhị phân gồm lớp Dương tính (Positive) và Âm tính (Negative), không gian kết quả được phân rã thành không gian xác suất có điều kiện gồm bốn phần tử đại số:

- *True Positive (TP)*: Số lượng mẫu có nhãn thực tế là Dương tính và được mô hình dự đoán chính xác là Dương tính.
- *True Negative (TN)*: Số lượng mẫu có nhãn thực tế là Âm tính và được mô hình dự đoán chính xác là Âm tính.

- *False Positive (FP)*: Số lượng mẫu có nhãn thực tế là Âm tính nhưng mô hình dự đoán sai thành Dương tính (Sai lầm loại I - Type I error).
- *False Negative (FN)*: Số lượng mẫu có nhãn thực tế là Dương tính nhưng mô hình dự đoán sai thành Âm tính (Sai lầm loại II - Type II error).

Đối với bài toán phân loại đa lớp, ta gọi M là ma trận nhầm lẫn kích thước $C \times C$ (với $C = 3$). Phần tử M_{ij} đại diện cho số lượng mẫu thuộc lớp thực tế i nhưng được hệ thống dự đoán thuộc lớp j . Khi đó, cấu trúc dữ liệu của từng lớp i ($i = 1, \dots, C$) theo chiến lược *One-vs-Rest* được định nghĩa thông qua các công thức sau:

- $TP_i = M_{ii}$
- $FP_i = \sum_{j \neq i}^C M_{ji}$
- $FN_i = \sum_{j \neq i}^C M_{ij}$
- $TN_i = \sum_{j \neq i}^C \sum_{k \neq i}^C M_{jk}$

3.2.1. Accuracy

Độ chính xác tổng thể Accuracy là tỷ số giữa số lượng điểm dữ liệu được mô hình dự đoán trùng khớp hoàn toàn với nhãn mục tiêu thực tế trên tổng số mẫu có trong tập dữ liệu kiểm tra. Trong không gian nhị phân, chỉ số được xác định qua biểu thức:

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}$$

Trong không gian đa lớp tổng quát với ma trận nhầm lẫn M , Accuracy là tỷ lệ giữa tổng các phần tử nằm trên đường chéo chính và tổng toàn bộ các phần tử có trong ma trận:

$$\text{Accuracy} = \frac{\sum_{i=1}^C M_{ii}}{\sum_{i=1}^C \sum_{j=1}^C M_{ij}}$$

Đối với đề tài này, Accuracy đóng vai trò là thước đo sơ bộ, cung cấp một biểu tượng hiệu năng trực quan và nhanh chóng về khả năng nhận diện sắc thái cảm xúc của mô hình SVM trên toàn bộ tập dữ liệu ý kiến sinh viên. Chỉ số này cho biết tổng thể có bao nhiêu phần trăm phản hồi được phân loại đúng nhãn. Tuy nhiên, Accuracy có một hạn chế mang tính hệ thống khi đối mặt với hiện tượng mất cân bằng lớp – tức là các nhãn phân loại trong bộ dữ liệu có sự phân bố không đồng đều (ví dụ trong biểu đồ *Hình*

1, số lượng câu tích cực và tiêu cực trong bộ dữ liệu UIT-VFSC thường áp đảo hoàn toàn các câu mang tính trung tính). Nếu một mô hình phân lớp thiên vị hoàn toàn về lớp đa số, chỉ số Accuracy vẫn đạt giá trị rất cao, tối băm đi năng lực phân loại của các lớp thiểu số. Do đó, Accuracy không được chọn làm chỉ số duy nhất để tối ưu hóa hệ thống.

3.2.2. Precision

Độ chính xác Precision là tỷ lệ giữa số lượng mẫu thực tế thuộc lớp Dương tính toàn phần trên tổng số lượng mẫu được mô hình định danh là Dương tính. Chỉ số này đại diện cho độ tin cậy của mô hình khi đưa ra quyết định cho một lớp cụ thể.

$$\text{Precision} = \frac{TP}{TP + FP}$$

Trong bài toán phân loại đa lớp, chỉ số Precision được tính toán riêng biệt cho từng lớp i dựa trên ma trận nhầm lẫn:

$$\text{Precision}_i = \frac{M_{ii}}{\sum_{j=1}^C M_{ji}}$$

Nhằm quy nạp về một giá trị duy nhất đại diện cho toàn hệ thống đa lớp, hai đại lượng trung bình hóa toán học được áp dụng cho đề tài này:

- *Macro-averaged Precision* ($\text{Precision}_{\text{macro}}$): Trung bình cộng phân phối đều trên tất cả các lớp, xem vai trò của mọi lớp là đẳng hướng:

$$\text{Precision}_{\text{macro}} = \frac{1}{C} \sum_{i=1}^C \text{Precision}_i$$

- *Micro-averaged Precision* ($\text{Precision}_{\text{micro}}$): Tổng các phần tử tương ứng trên toàn bộ không gian mẫu:

$$\text{Precision}_{\text{micro}} = \frac{\sum_{i=1}^C M_{ii}}{\sum_{i=1}^C \sum_{j=1}^C M_{ji}}$$

Trong việc phân tích phản hồi của sinh viên, chỉ số Precision giải quyết bài toán kiểm soát tỷ lệ báo động giả. Giả sử, đối với lớp nhãn "Tiêu cực" (Negative), Precision phải đủ cao để đảm bảo rằng khi mô hình trích xuất và cảnh báo một câu phản hồi là tiêu cực, thì phản hồi đó phải thực sự mang tính tiêu cực với độ tin cậy cao. Điều này giúp nhà trường và giảng viên tránh việc tiếp nhận và xử lý sai lệch các thông tin nhiễu hoặc các câu nói mang tính tích cực/trung tính bị nhận diện sai.

3.2.3. Recall

Độ bao phủ (độ nhạy) Recall là tỷ số giữa số lượng mẫu thuộc lớp Dương tính được hệ thống nhận diện chính xác trên tổng số lượng mẫu thực tế vốn thuộc về lớp Dương tính đó. Đại lượng này đo lường năng lực khai thác tối đa và không bỏ sót thông tin của mô hình.

$$\text{Recall} = \frac{TP}{TP + FN}$$

Trong bài toán đa lớp, công thức thể hiện độ bao phủ cho từng lớp cụ thể i như sau:

$$\text{Recall}_i = \frac{M_{ii}}{\sum_{j=1}^C M_{ij}}$$

Tương tự, cấu trúc trung bình hóa đa lớp của Recall bao gồm:

- *Macro-averaged Recall* ($\text{Recall}_{\text{macro}}$): Trung bình cộng phân phối đều trên tất cả các lớp, xem vai trò của mọi lớp là đẳng hướng:

$$\text{Recall}_{\text{macro}} = \frac{1}{C} \sum_{i=1}^C \text{Recall}_i$$

- *Micro-averaged Recall* ($\text{Recall}_{\text{micro}}$): Tổng các phân tử tương ứng trên toàn bộ không gian mẫu:

$$\text{Recall}_{\text{micro}} = \frac{\sum_{i=1}^C M_{ii}}{\sum_{i=1}^C \sum_{j=1}^C M_{ji}}$$

Nếu chỉ số Precision tập trung vào độ tin cậy, thì chỉ số Recall tập trung vào độ toàn vẹn. Đối với bộ dữ liệu UIT-VSFC, Recall của lớp "Tiêu cực" mang ý nghĩa sống còn đối với công tác bảo đảm chất lượng giáo dục. Một mô hình có Recall thấp đối với các phản hồi tiêu cực đồng nghĩa với việc hệ thống đã bỏ sót rất nhiều lời phê bình, đóng góp thẳng thắn hoặc những vấn đề bức xúc thực tế của sinh viên (đồng nghĩa giá trị FN cao). Việc bỏ sót này sẽ khiến các cấp quản lý khó tiếp cận được những lỗ hổng trong vận hành đào tạo để kịp thời điều chỉnh.

3.2.4. F1-Score

Trong thực tế, Precision và Recall thường tồn tại một mối quan hệ đánh đổi tỷ lệ nghịch. Để thiết lập một thước đo thống nhất dung hòa hai đại lượng này, F1-Score được xây dựng dựa trên nền tảng của Harmonic Mean (Trung bình điều hòa) giữa Precision và Recall. Sử dụng Harmonic Mean tức là phạt rất nặng những trường hợp có sự mất

cân bằng cực đoan giữa hai chỉ số thành phần. Hệ số F1-Score trong hệ nhị phân được phát biểu bằng biểu thức sau:

$$F1\text{-Score} = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}} = \frac{2TP}{2TP + FP + FN}$$

Đối với không gian phân loại đa lớp, mô hình sử dụng hai biến thể mở rộng:

- *Macro-averaged F1-Score* ($F1_{\text{macro}}$): Tính toán chỉ số F1 độc lập cho từng toán tử lớp, sau đó lấy trung bình đại số:

$$F1_i = 2 \cdot \frac{\text{Precision}_i \cdot \text{Recall}_i}{\text{Precision}_i + \text{Recall}_i}$$

$$F1_{\text{macro}} = \frac{1}{C} \sum_{i=1}^C F1_i$$

- *Weighted F1-Score* ($F1_{\text{weighted}}$): Khắc phục nhược điểm của Macro bằng cách nhân thêm trọng số phân phối mẫu, trong đó N_i là số lượng mẫu thực tế của lớp i và N là tổng số mẫu của toàn bộ ngữ liệu kiểm tra:

$$F1_{\text{weighted}} = \sum_{i=1}^C \left(\frac{N_i}{N} \cdot F1_i \right)$$

Do đặc thù của tập dữ liệu UIT-VSFC là phân loại đa lớp với 3 lớp Tích cực – Tiêu cực – Trung tính và có sự phân tán không đều về mặt mật độ mẫu giữa các nhãn, $F1_{\text{macro}}$ và $F1_{\text{weighted}}$ được lựa chọn làm những chỉ số cốt lõi, mang tính quyết định để đánh giá, nghiệm thu và so sánh hiệu năng của các cấu hình mô hình cấu trúc N-grams kết hợp với SVM. Một mô hình được chứng minh là tối ưu và có thể đưa vào ứng dụng thực tế khi và chỉ khi nó đạt được giá trị F1-Score cao và ổn định, chứng tỏ được năng lực phân loại đồng đều, chính xác và không thiên vị trên mọi khía cạnh cảm xúc.

CHƯƠNG 4. CÀI ĐẶT MÔ HÌNH VÀ KẾT QUẢ ĐÁNH GIÁ

4.1. Cài đặt mô hình

4.1.1. Môi trường thực nghiệm và hệ thống thư viện phẩm mềm

Toàn bộ quy trình phân tích cảm xúc dựa trên phản hồi của sinh viên được hiện thực hóa bằng ngôn ngữ lập trình Python phiên bản 3.10 trở lên, tận dụng các thư viện chuyên biệt mã nguồn mở uy tín phục vụ cho các tác vụ NLP và học máy, cụ thể:

- *Thư viện tách từ tiếng Việt (underthesea)*: Sử dụng hàm `word_tokenize(format='text')` nhằm gom cụm các cấu trúc từ phức đặc thù của tiếng Việt dựa trên mô hình chuỗi kết hợp từ điển học. Bước xử lý này được thực hiện độc lập và đồng bộ trên toàn bộ ngữ liệu trước khi đưa vào bộ trích xuất đặc trưng nhằm đảm bảo tính toàn vẹn ngữ nghĩa cục bộ của các unigram, bigram và trigram.
- *Thư viện học máy (scikit-learn)*: Giúp chuyển đổi biểu diễn văn bản sang trọng số thống kê TF-IDF (`TfidfVectorizer`), huấn luyện bộ phân lớp vector hỗ trợ tuyến tính (`LinearSVC`), quét vét cạn không gian tham số liên hợp (`GridSearchCV`) và đo lường các chỉ số hiệu năng hệ thống (`sklearn.metrics`).
- *Các thư viện phân tích và trực quan hóa dữ liệu (pandas, numpy, matplotlib, seaborn)*: Được sử dụng để cấu trúc hóa ma trận đặc trưng, tính toán các đại lượng phân phối thống kê và hiển thị trực quan các biểu đồ Learning Curves (biểu đồ đường học) cũng như Confusion Matrix (ma trận nhầm lẫn).

4.1.2. Thiết lập cấu trúc Pipeline và không gian siêu tham số

Nhằm giúp chuẩn hóa quy trình huấn luyện, một kiến trúc chuỗi scikit-learn Pipeline được thiết lập tuần tự gồm hai tầng xử lý:

- *Tầng trích xuất đặc trưng*: Chuyển đổi chuỗi văn bản đã tách từ thành không gian vector số thực bằng mô hình TF-IDF, sử dụng chuẩn hóa độ dài vector bậc hai (L_2 norm) nhằm loại bỏ sự ảnh hưởng của độ dài văn bản ngắn dài khác nhau. Để kiểm soát từ nhiễu, tham số `min_df=5` được áp dụng cố định nhằm loại bỏ tất cả các token xuất hiện ít hơn 5 lần trên toàn bộ ngữ liệu huấn luyện. Cấu hình cửa sổ ngữ cảnh ngram_range được thay đổi tuần tự qua 6 kịch bản đối sánh: (1,1), (1,2), (2,2), (1,3), (2,3), và (3,3).

- *Tầng bộ phân lớp học máy*: Sử dụng mô hình vector hỗ trợ tuyến tính LinearSVC với số vòng lặp tối đa `max_iter=2000` để đảm bảo điều kiện hội tụ toán học và thiết lập `random_state=42` phục vụ cho việc tái hiện thực nghiệm. Đặc biệt, tham số `class_weight='balanced'` được kích hoạt nhằm tự động hiệu chỉnh hàm phạt sai số tỷ lệ nghịch với tần suất xuất hiện của các nhãn lớp, giải quyết trực tiếp hiện tượng mất cân bằng dữ liệu.

Không gian siêu tham số liên hợp cần tối ưu hóa `param_grid` được cấu hình dưới dạng tích Descartes của hai tập hợp tham số cục bộ:

- Ngưỡng tần suất văn bản cực đại `max_df` $\in \{0.1, 0.2, 0.3, 0.4, 0.5, 0.6, 0.7, 0.8, 0.9\}$ (gồm 9 giá trị).
- Hệ số phạt biên mềm SVM `C` $\in \{0.2, 0.4, 0.6, 0.8, 1.0, 5.0, 10.0\}$ (gồm 7 giá trị).

Như vậy, ứng với mỗi cấu hình đặc trưng N-gram, không gian tìm kiếm bao gồm tổng cộng $9 \times 7 = 63$ siêu tham số khác nhau.

4.1.3. Chiến lược tối ưu hóa tham số và phương pháp đánh giá mô hình

Mô hình áp dụng thuật toán GridSearchCV thực hiện tìm kiếm vét cạn trên không gian lưới gồm 63 siêu tham số đã thiết lập. Quá trình tối ưu hóa kết hợp chặt chẽ với chiến lược ***k-fold Cross-Validation*** ($k = 5$). Tại mỗi phân đoạn, dữ liệu huấn luyện thô được phân rã ngẫu nhiên thành 5 tập con không chồng lấn; mô hình được huấn luyện trên 4 tập con và kiểm thử trên tập con còn lại, lặp lại luân phiên 5 lần. Tổng số lượt huấn luyện thực tế cho mỗi cấu hình đặc trưng là $63 \times 5 = 315$ lượt huấn luyện độc lập.

Do đặc thù mất cân bằng nghiêm trọng của bộ dữ liệu, chỉ số ***Macro F1-score*** được lựa chọn làm đại lượng mục tiêu giúp Grid Search tối ưu và lựa chọn mô hình tốt nhất thay vì sử dụng chỉ số Accuracy vốn rất dễ bị sai lệch bởi lớp đa số.

4.2. Kết quả huấn luyện


4.2.1. Kết quả tối ưu hóa siêu tham số (Grid Search Heatmap Analysis)

Quá trình Grid Search đánh giá chéo đã xác định được các tổ hợp siêu tham số tối ưu tối tuyệt đối ứng với từng không gian đặc trưng N-gram. *Bảng 2* dưới đây thể hiện kết quả điểm Macro F1 tốt nhất trên tập huấn luyện qua cơ chế k-fold CV ($k = 5$) cùng độ dao động giá trị hiệu năng (`score_range`) giữa cấu hình tham số tốt nhất và kém nhất.

Bảng 5. Kết quả tối ưu hóa siêu tham số trên không gian k-fold CV ($k = 5$)

Cấu hình N-gram	Tham số tối ưu max_df	Tham số tối ưu C	Chỉ số Marco-F1 tốt nhất (%)	Độ dao động hiệu năng (%)
(1, 1)	0.20	0.20	73.89	5.90
(1, 2)	0.20	0.20	75.37	3.67
(2, 2)	0.10	0.40	66.88	2.27
(1, 3)	0.20	0.20	75.09	4.04
(2, 3)	0.10	0.60	66.74	2.17
(3, 3)	0.10	0.20	50.67	0.54

Có thể thấy rằng, tất cả các cấu hình chứa đặc trưng từ đơn (Unigram) bao gồm (1,1), (1,2), và (1,3) đều đạt điểm có **tham số tối ưu max_df là 0.29** và **tham số tối ưu C là 0.20**. Điều này cho thấy rằng việc loại bỏ các thuật ngữ xuất hiện ở hơn 20% số lượng câu (vốn là các từ mang tính hành chính, dùng chung như *giảng viên*, *sinh viên*, *môn học*) giúp thanh lọc dữ liệu mạnh mẽ, đồng thời một biên phân lớp lỏng ($C = 0.2$) giúp thuật toán SVM chống lại hiện tượng quá khớp hiệu quả. Ngược lại, các không gian đặc trưng thuần bậc cao như Bigram (2,2) hay Trigram (3,3) có độ dao động hiệu năng cực nhỏ (đều dưới 2.5%) chứng tỏ chúng ít nhạy cảm với siêu tham số nhưng hiệu năng đạt được rất thấp do rơi vào bẫy thừa thớt đặc trưng.



Hình 4. Biểu đồ Heatmap

4.2.2. Kết quả phân loại tổng thể và đối sánh hiệu năng trên tập kiểm thử (Test Set)

Sau khi đóng băng các siêu tham số tối ưu thu được từ bước đánh giá chéo, mô hình tiến hành dự đoán thực tế trên tập kiểm thử độc lập. Kết quả đối sánh hiệu năng tổng thể giữa 6 cấu hình đặc trưng được trình bày cụ thể tại *Bảng 3*.

Bảng 6. Bảng đối sánh hiệu năng tổng thể của mô hình SVM trên tập kiểm thử

Cấu hình N-gram	Accuracy	Precision	Recall	F1 Score	Weighted F1
(1, 1)	0.8781	0.7296	0.7517	0.7386	0.8815
(1, 2)	0.8847	0.7338	0.7281	0.7304	0.8838
(1, 3)	0.8831	0.7313	0.7217	0.7256	0.8816
(2, 2)	0.8023	0.6522	0.6915	0.6572	0.8196
(2, 3)	0.8001	0.6475	0.6827	0.6517	0.8173
(3, 3)	0.6674	0.5278	0.4902	0.4763	0.6495

Xét chỉ số Accuracy, cấu hình tích hợp tổ hợp *Unigram + Bigram (1, 2)* mang lại độ chính xác cao nhất với **88.47%**. Kết quả này phản ánh đúng giả thuyết lý thuyết: sự bổ sung các cụm 2-từ liên kề cho phép mô hình thu giữ trọn vẹn ngữ nghĩa của các cấu trúc phủ định cục bộ (ví dụ: *không nhiệt_tình, chưa hiểu_bài*) mà cấu trúc unigram rời rạc dễ bỏ sót.

Xét chỉ số tối ưu đa lớp Macro F1, cấu hình *Unigram thuần (1, 1)* lại cho điểm Macro F1 cao nhất với **73.86%**. Nguyên nhân sâu xa nằm ở hiện tượng bùng nổ số chiều đặc trưng thưa (Sparsity). Khi nâng cấu hình từ (1,1) lên (1,2) và (1,3), số lượng đặc trưng tăng lên theo cấp số nhân nhưng phần lớn giá trị bằng 0. Trong không gian quá thưa thớt này, ranh giới siêu phẳng quyết định của SVM đối với nhãn thiểu số (Trung lập) vốn đã có rất ít mẫu sẽ bị ép chặt và lấn át bởi hai lớp đa số, làm suy giảm năng lực nhận diện nhãn thiểu số và kéo chỉ số Macro F1 tổng thể đi xuống.


Các cấu hình thuần Bigram (2,2) và thuần Trigram (3,3) cho kết quả sụt giảm nghiêm trọng, trong đó Trigram thuần chỉ đạt **47.63%** Macro F1. Điều này minh chứng rằng trong ngôn ngữ phản hồi của sinh viên, tính lặp lại của một cụm 3 từ cố định là cực kỳ thấp; việc loại bỏ hoàn toàn các từ đơn lẻ làm triệt tiêu các từ khóa mang từ tính biểu cảm cốt lõi (như *tốt, chê, tệ*), khiến mô hình rơi vào trạng thái thiếu khớp dữ liệu (Underfitting).

4.2.3. Phân tích cụ thể từng lớp và ma trận nhầm lẫn

Để có cái nhìn toàn diện và sâu sắc về khả năng phân loại cục bộ của thuật toán SVM trên từng sắc thái cảm xúc cụ thể, nhóm đã tiến hành thiết lập một ma trận đối sánh hiệu năng chi tiết. Dữ liệu hiệu năng phân lớp của từng nhãn mục tiêu gồm Tiêu cực (0), Trung lập (1), và Tích cực (2) ứng với toàn bộ 6 cấu hình đặc trưng N-gram trên tập kiểm thử được tổng hợp tại Bảng 4 và đã trực quan hóa thông qua 06 ma trận nhầm lẫn ứng với mỗi cấu hình N-gram ở Hình 5.

Bảng 7. Bảng tổng hợp chi tiết hiệu năng phân loại theo từng nhãn của 6 cấu hình N-gram

STT	Các mô hình N-gram	Nhãn	Precision	Recall	F1 score
1	Unigram (1, 1)	Tiêu cực (0)	0.8864	0.9191	0.9024
		Trung lập (1)	0.3606	0.4491	0.4
		Tích cực (2)	0.9419	0.8868	0.9135
2	Unigram + Bigram (1, 2)	Tiêu cực (0)	0.8828	0.9354	0.9083
		Trung lập (1)	0.3806	0.3533	0.3665
		Tích cực (2)	0.9381	0.8956	0.9163
3	Bigram (2, 2)	Tiêu cực (0)	0.8509	0.8467	0.8488
		Trung lập (1)	0.1994	0.4251	0.2715
		Tích cực (2)	0.9062	0.8025	0.8512
4	Unigram + Bigram+ Trigram (1, 3)	Tiêu cực (0)	0.8799	0.9361	0.9072
		Trung lập (1)	0.3784	0.3353	0.3556
		Tích cực (2)	0.9355	0.8937	0.9141
5	Bigram + Trigram (2, 3)	Tiêu cực (0)	0.851	0.8432	0.8471
		Trung lập (1)	0.1903	0.4012	0.2582
		Tích cực (2)	0.9013	0.8038	0.8497
6	Trigram (3, 3)	Tiêu cực (0)	0.5923	0.9155	0.7193
		Trung lập (1)	0.1061	0.0419	0.0601
		Tích cực (2)	0.885	0.5132	0.6497



Hình 5. Ma trận nhầm lẫn

Dựa trên số liệu thống kê và các biểu đồ ma trận nhầm lẫn trích xuất từ thực nghiệm, ta có thể chia thành các nhóm xu hướng cú pháp sau:

4.2.3.1. Nhóm 1 - Các mô hình tích hợp đặc trưng từ đơn

Các cấu hình có sự xuất hiện của Unigram giữ vai trò thống trị về mặt hiệu năng phân lớp.

- *Mô hình Unigram + Bigram (1,2)* tối ưu hóa xuất sắc năng lực nhận diện trên hai không gian mẫu lớn, đạt F1-Score lớp Tiêu cực là 0.91 và lớp Tích cực là 0.92. Ma trận nhầm lẫn của Mô hình 2 ghi nhận tỷ lệ bao phủ (Recall) lớp Tiêu cực vượt trội lên đến 0.9354. Điều này chứng minh rằng việc kết hợp các tổ hợp cụm từ liên kề giúp thuật toán bắt giữ hiệu quả các mẫu câu phủ định ngắn hoặc cấu trúc Teencode lặp lại của sinh viên.
- *Mô hình Unigram (1,1)* dù sụt giảm nhẹ ở các lớp đa số, nhưng lại là cấu hình giải quyết tốt nhất bài toán nhận diện nhãn thiếu số Trung lập với điểm F1-Score đạt cực đại toàn hệ thống là 0.40 và Recall đạt 0.4491.
- *Mô hình Unigram + Bigram + Trigram (1,3)* khi tích hợp thêm đặc trưng Trigram bắt đầu cho thấy dấu hiệu sụt giảm hiệu năng cục bộ tại nhãn Trung lập (Recall giảm từ 0.4491 xuống 0.3353).

Đối với cả 3 mô hình thuộc nhóm này, ma trận nhầm lẫn đều chỉ ra một hành vi sai lệch mang tính quy luật: *Cặp nhầm lẫn lớn nhất luôn xảy ra từ nhãn Tích cực (2) sang nhãn Tiêu cực (0)*. Cụ thể, số lượng mẫu câu bị phân loại sai ở xung đột này lần lượt là **114 câu** đối với cấu hình (1,1), **117 câu** đối với cấu hình (1,2), và **119 câu** (đối với cấu hình (1,3)).

Bản chất của sai số này xuất phát từ việc các mô hình tích hợp Unigram bất lực trước các phản hồi có tính chất đa vế hoặc đảo ngữ phức tạp (Ví dụ: *Giảng viên dạy rất nhiệt tình nhưng phòng học nóng quá không thể tập trung*). Trọng số TF-IDF ghi nhận cả hai nhóm từ vựng phân cực mạnh, và thuật toán SVM tuyến tính có xu hướng bị kéo lệch biên quyết định về phía không gian có mật độ từ ngữ chiếm ưu thế cấu trúc về sau.

4.2.3.2. Nhóm 2 - Các mô hình thuần bậc cao và tổ hợp bậc cao thiếu Unigram

Khi loại bỏ hoàn toàn tầng đặc trưng từ đơn Unigram, hiệu năng của thuật toán SVM sụt giảm nghiêm trọng và bộc lộ các lỗi hổng phân lớp lớn.

- *Mô hình (2,2)* và *Mô hình (2,3)* có xu hướng dịch chuyển ranh giới quyết định rất giống nhau. Điểm F1-Score của lớp Tiêu cực và Tích cực đồng loạt dừng lại ở mức 0.85. Đáng chú ý, ma trận nhầm lẫn của nhóm này chỉ ra


rằng: *Cặp nhầm lẫn lớn nhất đã chuyển dịch từ Tích cực (2) sang Trung lập (1) với 164 câu bị đoán sai ở cấu hình Bigram thuần và 167 câu ở cấu hình Bigram + Trigram. Nguyên nhân là do các cụm 2-từ (Bigram) trong câu tích cực khi đứng độc lập bị mất đi các từ hỗ trợ sắc thái gốc (như các từ đơn *rất, quá, được*), làm suy giảm độ lớn của vector đặc trưng và khiến chúng bị rơi vào vùng không gian mờ nằm sát ranh giới của nhãn Trung lập.*

- *Mô hình (3,3) là cấu hình có hiệu năng thấp nhất trong nghiên cứu. Ma trận nhầm lẫn của Trigram đã chứng minh được sự sụp đổ hoàn toàn trong năng lực phân loại đối với nhãn thiểu số: Recall của lớp Trung lập chạm đáy ở mức 0.0419 (tức là mô hình bỏ sót đến 95.81% các câu trung lập thực tế).*


Đồng thời, sai số nhầm lẫn từ nhãn **Tích cực sang Tiêu cực bùng nổ lên con số kỷ lục là 741 câu**. Do các cụm 3 từ tiếng Việt có tính lặp lại cực kỳ thấp trong tập huấn luyện, ma trận TF-IDF sinh ra gần như là một ma trận rỗng (Zero Matrix). Thuật toán SVM hoàn toàn bị mất đi các vector hỗ trợ sinh trị, dẫn đến việc ranh giới quyết định bị sụp đổ và mô hình có xu hướng quy chụp phần lớn dữ liệu kiểm thử về lớp Tiêu cực.

4.2.4. Khảo sát biến động đường học (Learning Curves)

Trong nghiên cứu thực nghiệm học máy ứng dụng vào Xử lý ngôn ngữ tự nhiên, đường học (Learning Curve) là công cụ toán học trực quan và mạnh mẽ để đánh giá mối quan hệ biến chứng giữa hiệu năng dự đoán của mô hình và quy mô của tập dữ liệu huấn luyện. Nhóm đã tiến hành cô lập và đóng băng các bộ siêu tham số ($\max_df, C$) tối ưu đã tìm được ở bước đánh giá chéo cross-validation. Sau đó, dữ liệu huấn luyện thô được tăng trưởng lũy tiến qua 9 mốc kích thước. Hiệu năng phân lớp tương ứng kiểm thử độc lập trên tập Test ứng với chỉ số Accuracy và chỉ số Macro F1-Score được thông kê ở *Hình 6* và *Hình 7*, từ đó nhóm thực hiện đã phát hiện được một số hiện tượng đáng chú ý ở cả hai biểu đồ như sau:



Hình 6. Biểu đồ Learning Curves cho chỉ số Accuracy với các mô hình N-gram tương ứng



Hình 7. Biểu đồ Learning Curves cho chỉ số Marco F1-score với các mô hình N-gram tương ứng

4.2.4.1. Tốc độ học ấn tượng ở giai đoạn đầu

Một phát hiện quan trọng từ Learning Curves cho thấy các cấu hình đặc trưng chứa Unigram gồm Mô hình 1, 2 và 4 có **tốc độ học rất tốt ở giai đoạn đầu**. Chỉ 500 câu khởi đầu, các mô hình này đã đạt mức Accuracy vượt ngưỡng 0.82 và Macro F1 trên 0.61.

Điều này chứng minh được rằng không gian vector tạo bởi Unigram kết hợp trọng số TF-IDF có mật độ phân phối sinh trị đặc trưng rất cao. Các từ đơn mang từ tính cảm xúc mạnh (như *hay*, *tệ*, *vui*, *chán*) xuất hiện phổ biến và nhất quán, cho phép thuật toán SVM tuyến tính nhanh chóng xác định được các vector hỗ trợ cốt lõi để dựng lên siêu phẳng phân hoạch thô có độ chính xác cao mà không đòi hỏi quá nhiều chi phí dữ liệu.

Ngược lại, cũng 500 câu mẫu ở thời điểm xuất phát, các mô hình loại bỏ Unigram như Trigram thuần (3,3) lại có Accuracy đạt tầm 0.49 và Macro F1 đạt chỉ số rất thấp ở mức 0.26. Con số này phản ánh trạng thái "mù đặc trưng" do mật độ từ vựng bậc cao quá thừa thớt trên dung lượng mẫu nhỏ khiến thuật toán tối ưu của SVM hoàn toàn bất lực trong việc tìm kiếm biên phân lớp.

4.2.4.2. Hiện tượng bão hòa hiệu năng và giới hạn tiệm cận phẳng

Đồ thị Learning Curves của cả 6 cấu hình đều thể hiện cùng một xu hướng: *Dốc lên rất mạnh từ mốc 500 đến 4,000 mẫu, sau đó giảm dần và tiến vào vùng tiệm cận phẳng bão hòa bắt đầu từ ngưỡng 8,000 mẫu trở đi.*

- **Xét mô hình Unigram (1,1):** Chỉ số Macro F1 tăng trưởng mạnh từ 0.62 đến 0.74 trong khoảng từ 500 đến 4000 mẫu. Tuy nhiên, bắt đầu từ khoảng 8000 mẫu đến hết, chỉ số Macro F1 không những không tăng mà còn có xu hướng dao động nhẹ và dừng lại ở mức 0.74. Phát biểu trên cũng hoàn toàn chính xác khi nói về chỉ số Accuracy.
- **Xét mô hình Unigram + Bigram (1,2):** Chỉ số Accuracy tịnh tiến đều trong khoảng 1000 đến 13009 mẫu và đạt 0.88. Tuy nhiên, chỉ số F1-score lại có sự biến thiên nhẹ tại mốc 10000 mẫu khi giảm từ 0.72 xuống 0.71 và tăng tiến đến 0.73 tại mốc 13009 mẫu,

Hiện tượng bão hòa này đã khẳng định rằng: Với kiến trúc tuyến tính của bộ phân lớp SVM truyền thống, dung lượng dữ liệu hiện tại đã đạt đến **trạng thái bão hòa thông tin** đối với bài toán phân tích cảm xúc. Việc đổ thêm hàng nghìn câu phản hồi thô có cấu trúc tương tự vào hệ thống sẽ không giúp nâng cao ranh giới quyết định của siêu phẳng do giới hạn năng lực biểu diễn phi ngữ cảnh của mô hình túi từ (Bag-of-Words).

4.2.4.3. Mối quan hệ giữa Bias - Variance và cấu trúc chiều không gian vector

Hành vi biến động đường học Learning Curves của chỉ số Macro F1 tại các mốc dữ liệu lớn đã cho thấy sự đánh đổi giữa Độ chệch (Bias) và Phương sai (Variance).

Đối với cấu hình Unigram (1,1), chỉ số Macro F1 đạt giá trị 0.75 tại mốc 10,000 mẫu, sau đó sụt giảm nhẹ về 0.74 tại mốc 13,009 mẫu. Khi phân tích ma trận nhầm lẫn tương ứng, nguyên nhân là do khi nạp thêm dữ liệu từ mốc 10,000 trở đi, số lượng câu Tích cực và Tiêu cực (lớp đa số) nạp vào tăng lên lần lượt lớp Trung lập (lớp thiểu số). Thuật toán SVM biên mềm lúc này bị ép phải tối ưu hóa hàm phạt phải phạt sai số tổng thể, dẫn đến việc dịch chuyển nhẹ siêu phẳng quyết định để làm hài lòng lớp đa số, vô tình làm co hẹp biên phân lớp của nhãn Trung lập, gây sụt giảm chỉ số Macro F1.

Xét cả hai chỉ số Accuracy và Macro F1, đường học của các mô hình tổ hợp (1,2) và (1,3) luôn duy trì xu hướng tịnh tiến dốc lên ổn định, phẳng đều ở giai đoạn cuối và không hề xảy ra hiện tượng đảo chiều sụt gãy đột ngột. Đây là minh chứng khẳng định mô hình *hoàn toàn vô hiệu hóa trước rủi ro quá khớp (Overfitting)*. Mặc dù số chiều đặc trưng N-gram bùng nổ lên tới hàng chục nghìn chiều, việc áp dụng hàm chuẩn hóa vector bậc hai L_2 kết hợp với tham số phạt biên mềm $C = 0.2$ thấp đã kiểm soát được độ phức tạp của mô hình, giúp SVM giữ vững khả năng tổng quát hóa ổn định trên tập kiểm thử độc lập.

Chương 5. KẾT LUẬN

4.1. Ưu điểm

Nhóm thực hiện đã thực thi thành công quy trình phân loại văn bản kinh điển kết hợp giữa tăng trích xuất đặc trưng thống kê TF-IDF và bộ phân lớp SVM tuyến tính (LinearSVC). Mô hình Unigram + Bigram (1,2) đạt chỉ số Accuracy cao nhất với **88.47%** và mô hình Unigram (1,1) đạt chỉ số F1-Score cao nhất với **73.86%**. Kết quả này chứng minh tính đúng đắn của phương pháp luận, đạt ngưỡng hiệu năng tương đương và cải tiến nhẹ về mặt phân tách đơn vị từ nghĩa so với công bố baseline trong bài báo gốc của nhóm tác giả.

Toàn bộ quy trình từ trích xuất đặc trưng đến huấn luyện và tối ưu siêu tham số đều được đóng gói nhất quán trong cấu trúc `scikit-learn` kết hợp với tìm kiếm lưới và đánh giá chéo 5 phân đoạn (GridSearchCV). Sự kết hợp này giúp tự động hóa hoàn toàn quy trình thực nghiệm, tối ưu hóa thành công các cặp tham số liên hợp (`max_df, C`) một cách khách quan.

Việc sử dụng thư viện `underthesea` để thực hiện tách từ (Word Segmentation) thay thế cho các bộ tách từ thế hệ cũ đã giúp chuẩn hóa ngữ liệu thô về đúng đơn vị từ vựng tiếng Việt. Bước đi này là tiền đề để bộ trích xuất N-gram hoạt động chính xác ở các tầng cú pháp bậc cao, loại bỏ nhiễu do khoảng trắng âm tiết tính của chữ quốc ngữ gây ra.

Mặc dù việc mở rộng không gian từ Unigram sang Bigram và Trigram làm bùng nổ số chiều vector đặc trưng lên hàng chục nghìn chiều, mô hình vẫn duy trì khả năng tổng quát hóa cực kỳ ổn định. Việc kết hợp chuẩn hóa độ dài vector bậc hai (L_2 norm), hạ thấp ngưỡng phạt biên mềm ($C = 0.2$) và loại bỏ từ nhiễu với tham số `max_df` đã kiểm soát chặt chẽ hàm độ phức tạp toán học của SVM được minh chứng rõ nét qua các đường học (Learning Curves) phẳng đều vững chắc ở giai đoạn sau của quá trình huấn luyện.

4.2. Nhược điểm

Thực nghiệm đối sánh chỉ ra lỗ hổng lớn của các đặc trưng bậc cao thuần túy. Khi tách rời khỏi từ đơn Unigram, cấu hình Bigram (2,2) và đặc biệt là Trigram (3,3) rơi vào trạng thái thiếu khớp dữ liệu (Underfitting) trầm trọng (*Mô hình Trigram chỉ đạt 47.63% F1-score*). Do tính lặp lại của một cụm 3 từ cố định trong văn nói của sinh viên là cực kỳ thấp, ma trận TF-IDF sinh ra bị rỗng hóa trên diện rộng, làm triệt tiêu không gian vector hỗ trợ sinh trị và vô hiệu hóa ranh giới quyết định của siêu phẳng SVM.

Mặc dù đã kích hoạt tham số cân bằng trọng số phạt `class_weight='balanced'`, hệ thống vẫn bộc lộ sự yếu kém nghiêm trọng khi nhận diện nhãn thiểu số Trung lập (Neutral). Chỉ số Recall của nhãn Trung lập dao động rất thấp

(0.35 - 0.45), và chạm đáy ở mức **0.0419** đối với cấu hình Trigram (bỏ sót đến hơn 95% các câu trung lập thực tế). Điều này phản ánh đặc thù nghèo nàn về mật độ mẫu của ngữ liệu UIT-VSFC, khiến mô hình không tích lũy đủ thông tin để định hình biên quyết định rõ ràng.

Thông kê ma trận nhầm lẫn vạch trần lỗi sai phổ biến và nghiêm trọng nhất của các mô hình dẫn đầu là nhầm lẫn trầm trọng giữa hai thái cực đối lập hoàn toàn: *Tích cực (2) đoán sai sang nhãn Tiêu cực (0)*, dao động từ **114 đến 119 câu** trên toàn bộ các cấu hình chứa unigram. Do bản chất cấu trúc N-gram kết hợp TF-IDF vẫn là mô hình biểu diễn từ vựng tĩnh phi ngữ cảnh, hệ thống hoàn toàn bất lực trước các câu phản hồi đa vế có chứa liên từ nghịch đối. Mô hình đếm tần suất từ vựng đơn thuần sẽ bị kéo lệch biên quyết định về phía không gian về câu chiếm ưu thế chữ viết mà bỏ sót mạch logic đảo ngược của toàn câu văn.

4.3. Hướng phát triển

Để khắc phục triệt để điểm yếu "mù ngữ cảnh dài" của cấu trúc túi từ truyền thống, nghiên cứu tiếp theo có thể ứng dụng các mạng nơ-ron hồi quy có bộ nhớ dài (LSTM/Bi-LSTM) nhằm thu giữ các thông tin phủ định tầm xa. Đặc biệt, đề xuất hướng đi tối ưu nhất là tích hợp các mô hình ngôn ngữ lớn dựa trên kiến trúc Transformer đã được tiền huấn luyện chuyên biệt cho tiếng Việt. Cơ chế tự chú ý (Self-Attention) của Transformer cho phép mô hình gán trọng số năng động vào các liên từ nghịch đối (như *nhưng, tuy nhiên*) và các từ bổ trợ sắc thái, từ đó giải quyết triệt để lỗi nhầm lẫn ngữ nghĩa giữa hai thái cực Tích cực - Tiêu cực trong các cấu trúc câu phức đa vế.

Nhằm cứu vãn chỉ số Recall của nhãn thiểu số Trung lập, ta có thể áp dụng thuật SMOTE (Synthetic Minority Over-sampling Technique) tại không gian nhúng để sinh thêm các điểm dữ liệu nhân tạo cho lớp Trung lập trước khi đưa vào bộ phân lớp. Đồng thời, có thể thay thế hàm mất mát Cross-Entropy tiêu chuẩn bằng Focal Loss - một hàm mất mát có cơ chế tự động hạ thấp trọng số của các mẫu dễ phân loại (Tích cực/Tiêu cực) và tăng cường độ lớn của gradient phạt đối với các mẫu khó và hiếm (Trung lập), buộc mô hình phải tập trung học các đặc trưng thưa.

Vì dữ liệu phản hồi của sinh viên mang tính đặc thù cao, một câu văn thường chứa đựng nhiều luồng thái độ đối lập hướng vào các thực thể giáo dục khác nhau, nên việc quy chụp toàn bộ câu văn phức này vào một nhãn cảm xúc duy nhất là một sự khiên cưỡng về mặt ngữ nghĩa học. Do đó, hướng phát triển tự nhiên và mang giá trị thực tiễn cao nhất của đề tài là phân rã bài toán thành ABSA (Aspect Based Sentiment Analysis). Hệ thống tiếp theo sẽ đồng thời nhận diện cặp thực thể giúp nhà trường trích xuất được chính xác nội dung sinh viên hài lòng hoặc phàn nàn, phục vụ tối ưu cho công tác bảo đảm chất lượng đào tạo.

TÀI LIỆU THAM KHẢO

PHỤ LỤC