

SemEval-2025 Task 2: Entity-Aware Machine Translation

Phạm Phương Minh Trí - 21522708

Huỳnh Thị Hải Châu - 22520148

Nguyễn Hoàng Gia An - 22520021

University of Information Technology, VNU-HCM

Abstract

Các thực thể có tên (Named-Entities hoặc NE) có vai trò quan trọng trong việc duy trì ngữ cảnh và truyền đạt thông tin chính xác trong việc dịch máy (Machine Translation hoặc MT). Thách thức trong nhiệm vụ này nằm ở cách xử lý sự đa dạng, sự mơ hồ, hiếm hoi của các NE trong MT. Trong nhiệm vụ 2 của cuộc thi SemEval-2025 lần này, đề bài yêu cầu thực hiện việc dịch máy và nhận dạng các NE giữa tiếng Anh và nhiều ngôn ngữ khác. Giữa các mô hình thực hiện nhiệm vụ dịch máy và nhận dạng các NE, chúng em chọn mô hình mT5 vì mô hình đã cho thấy sự tiềm năng của mình khi cho ra kết quả tốt trong thí nghiệm generative và nhận dạng NE giữa nhiều ngôn ngữ.

Contents

1	Giới thiệu	1	3.7.3	Định dạng hướng dẫn (Instruction Formatting)	6
1.1	Các nhiệm vụ cần giải quyết	1	3.8	Đánh giá mô hình	6
1.2	Các vấn đề trong dịch máy	2	3.8.1	Thang đo BLEU	6
1.3	Language Model	2	3.8.2	Evaluation metrics của cuộc thi	7
2	Bộ dữ liệu	2	4	Cài đặt thí nghiệm	8
2.1	Tổng quan	2	4.1	Thực nghiệm	8
2.2	Phân tích bộ dữ liệu	2	4.2	Nền tảng thực nghiệm	8
2.2.1	Giới thiệu tổng quan	2	4.3	Phân tích và tiền xử lý dữ liệu	8
2.2.2	Cấu trúc bộ dữ liệu	3	4.4	Cài đặt mô hình	8
3	Phương pháp luận	4	4.5	Chia bộ dữ liệu	8
3.1	Hướng thực hiện	4	4.6	Kết luận	8
3.2	Nhiệm vụ dịch máy (Machine Translation)	4	5	Kết quả thí nghiệm	9
3.3	Nhiệm vụ nhận diện chủ thể có tên (Named Entity Recognition)	4	1	Giới thiệu	
3.4	Huấn luyện đa nhiệm (Multi-task Training)	5	1.1	Các nhiệm vụ cần giải quyết	
3.5	Mô hình ngôn ngữ mT5	5			
3.6	Thư viện xử lý ngôn ngữ tự nhiên Spacy	5			
3.7	Chuẩn bị dữ liệu	5			
3.7.1	Lọc dữ liệu	5			
3.7.2	Gán nhãn thực thể có tên (Named-entity Tagging)	6			

Trong nhiệm vụ 2 của cuộc thi SemEval-2025, chúng ta cần dịch một văn bản đầu vào từ ngôn ngữ nguồn (tiếng Anh) sang ngôn ngữ đích, trong đó những thực thể có tên ở các câu đầu vào có thể gây khó khăn cho hệ thống dịch do sự hiếm, mơ hồ hoặc chưa nằm trong kiến thức của hệ thống dịch. Đây chính là sự khác biệt lớn nhất giữa việc dịch máy đơn thuần và dịch máy nhận dạng chủ

thể.

Nhóm chúng em sẽ chia ra thành 3 nhiệm vụ nhỏ: Named Entity Recognition (nhận diện thực thể có tên), Machine Translation (dịch máy) và Entity-aware Machine Translation (dịch máy nhận diện thực thể).

1.2 Các vấn đề trong dịch máy

Khi sử dụng dịch máy (MT), các thực thể có tên (như tên riêng, địa danh, tổ chức, thuật ngữ kỹ thuật...) thường gặp lỗi dịch hoặc bị thay đổi không mong muốn. Nguyên nhân:

- Nhận dạng sai thực thể (Apple → "Quả táo").
- Thiếu dữ liệu huấn luyện về thực thể.
- Dịch từ nguyên (Amazon → "Sông Ama-

zon").

- Không hiểu ngữ cảnh

1.3 Language Model

Language Model (LM) là một mô hình đại diện cho những kiến thức đã biết về một ngôn ngữ, những kiến thức ấy có thể là những từ, chuỗi các từ có thể có hay mức độ thường xuyên mà chúng xuất hiện.

LM có nhiều ứng dụng như Chatbot, dịch máy, tóm tắt văn bản, và tìm kiếm thông tin. Các mô hình tiên tiến như GPT-4 và BERT đã thúc đẩy những tiến bộ vượt bậc trong xử lý ngôn ngữ tự nhiên. LM được chia thành ba nhóm đó là Statistical LM (Count-based), Neural Network LM (Continuous-space) và Knowledge-based LM.

2 Bộ dữ liệu

2.1 Tổng quan

Bộ dữ liệu mẫu cuộc thi cung cấp bao gồm các cột chính như sau:

- Source: Đoạn văn bản nguồn bằng tiếng Anh
- Target: Đoạn văn bản đích được viết ở một ngôn ngữ khác
- Mention: Tên thực thể sau khi đã được dịch sang ngôn ngữ đích
- Source Locale: Ngôn ngữ nguồn (tiếng Anh)
- Target Locale: Ngôn ngữ đích (là một trong các ngôn ngữ trong đề bài của cuộc thi)

2.2 Phân tích bộ dữ liệu

2.2.1 Giới thiệu tổng quan

Bộ dữ liệu cho nhiệm vụ này được cung cấp ở định dạng JSONL, bao gồm văn bản nguồn tiếng

Anh và các bản dịch sang nhiều ngôn ngữ đích khác nhau. Dữ liệu cũng bao gồm các thực thể có tên được đề cập trong các bản dịch, dựa trên các thực thể từ Wikidata.

Một dòng dữ liệu mẫu bao gồm các phần:

- **ID:** là mã định danh duy nhất cho một dòng dữ liệu, thường có định dạng **<entity_id>_<q_id>** với **<entity_id>** là mã định danh thực thể và **<q_id>** là mã định danh câu hỏi (từ 0 đến 4).
- **Wikidata ID:** là mã định danh của thực thể trong Wikidata.
- **Source:** là văn bản nguồn bằng tiếng Anh.
- **Targets:** là bản dịch sang ngôn ngữ đích, trong đó mỗi bản dịch bao gồm:
 - **Translation:** là bản dịch của văn bản trong ngôn ngữ đích.
 - **Mention:** đề cập đến thực thể trong bản dịch.
- **Source Locale:** là ngôn ngữ nguồn (tiếng

Anh).

- **Target Locale:** là ngôn ngữ đích, bao gồm các ngôn ngữ sau:
 - Italian (it): sample, training, and evaluation data
 - Spanish (es): sample, training, and evaluation data
 - French (fr): sample, training, and evaluation data
 - German (de): sample, training, and evaluation data
 - Arabic (ar): sample, training, and evaluation data
 - Japanese (ja): sample, training, and evaluation data
 - Chinese (zh): sample and evaluation data
 - Korean (ko): sample and evaluation data
 - Thai (th): sample and evaluation data
 - Turkish (tr): sample and evaluation data

ID: Q2461698_0

Wikidata ID: Q2461698

Entity Types:

Fictional entity

Source: Who are the main antagonistic forces in the World of Ice and Fire?

Targets:

Translation: Chi sono le principali forze antagoniste nel mondo delle Cronache del ghiaccio e del fuoco?

Mention: **mondo delle Cronache del ghiaccio e del fuoco**

Source Locale: en

Target Locale: it

Hình 1. Ví dụ cấu trúc của một dòng dữ liệu mẫu

Như ví dụ ở Hình 1, Tên tác phẩm "The World of Ice and Fire" đã được dịch sang tiếng Italy (it) thành "mondo delle Cronache del ghiaccio e del fuoco"

2.2.2 Cấu trúc bộ dữ liệu

Dữ liệu được chuẩn bị cho việc dịch máy và nhận dạng thực thể lấy từ nguồn được cung cấp theo nhiều giai đoạn:

- Dữ liệu mẫu để người tham gia có cái nhìn về định dạng dữ liệu và nhiệm vụ cần làm.
- Dữ liệu huấn luyện được phát hành tiếp theo để người tham gia bắt đầu huấn luyện mô hình của mình.
- Dữ liệu đánh giá (bao gồm các tham chiếu đích) sẽ được phát hành sau đó để người tham gia đánh giá mô hình của mình.
- Dữ liệu dự đoán mẫu là dữ liệu được dự đoán bởi mô hình GPT4o và GPT4o-mini để người tham gia tham khảo.

Các tham chiếu đích cho dữ liệu đánh giá sẽ được phát hành sau khi giai đoạn đánh giá kết thúc.

```
"source": "Did Gone With The Wind come out before 1940?",  
"target": "Via col vento è uscito prima del 1940?",  
"entities": ["Q2875"],  
"source_locale": "en",  
"target_locale": "it",  
"instance_id": "826528e6",  
"from": "mintaka",
```

Hình 2. Ví dụ cấu trúc của một dòng dữ liệu huấn luyện

Như trên hình 2, kiến trúc của một dòng dữ liệu huấn luyện bao gồm:

- **Source:** là văn bản nguồn bằng tiếng Anh
- **Target:** là văn bản đích bằng ngôn ngữ khác
- **Entities:** là mã định danh thực thể từ Wiki-data được nhắc đến trong văn bản nguồn
- **Source Locale:** là ngôn ngữ nguồn (Tiếng Anh)
- **Target Locale:** là văn bản nguồn bằng tiếng Anh
- **From:** là nguồn lấy của dòng dữ liệu

3 Phương pháp luận

3.1 Hướng thực hiện

Để giải quyết bài toán Entity-Aware Machine Translation (EA-MT) từ tiếng Anh sang các ngôn ngữ khác, nhóm đã xây dựng một quy trình thực hiện chi tiết, bắt đầu từ việc lựa chọn mô hình tiền huấn luyện đến các bước chuẩn bị dữ liệu, tiền xử lý, và huấn luyện mô hình. Mô hình mT5 (Multilingual Text-to-Text Transfer Transformer) được lựa chọn làm nền tảng do khả năng tổng quát hóa tốt trên các ngôn ngữ đa dạng nhờ được tiền huấn luyện trên các kho ngữ liệu lớn. Đặc biệt, với các ngôn ngữ phổ biến (resource-rich languages), chất lượng dữ liệu tinh chỉnh (fine-tuning) đóng vai trò quan trọng hơn số lượng dữ liệu, do đó nhóm tập trung vào việc chuẩn bị dữ liệu chất lượng cao.

Đầu tiên, nhóm sẽ lọc đi các dữ liệu gây nhiễu trong bộ dữ liệu được cuộc thi cung cấp. Sau đó tạo các bộ dữ liệu song song cho các tác vụ dịch máy (MT), gán nhãn chủ thể có tên (NER) và dịch máy nhận dạng chủ thể (EA-MT). Đối với mỗi tác vụ, các hướng dẫn (instruction format) được thêm vào phía nguồn để chỉ định nhiệm vụ cụ thể trên những bộ dữ liệu đó để mô hình dự đoán ra kết quả như nhóm mong đợi. Dữ liệu nguồn được thêm vào các nhãn thực thể có tên (Named-entity tag) khi cần thiết, trong khi dữ liệu mục tiêu có thể được thêm hoặc không tùy theo yêu cầu của mỗi tác vụ. Cách tiếp cận này giúp mô hình hiểu rõ nhiệm vụ và dự đoán kết quả chính xác hơn, đồng thời nâng cao chất lượng tổng thể của hệ thống dịch máy nhận biết thực thể.

3.2 Nhiệm vụ dịch máy (Machine Translation)

Dịch máy là tác vụ chuyển đổi văn bản từ ngôn ngữ nguồn (source language) sang ngôn ngữ mục tiêu (target language). Trong cuộc thi lần này, ta dịch văn bản từ ngôn ngữ gốc là tiếng Anh sang các ngôn ngữ trong nhiệm vụ của cuộc thi.

Mục tiêu là tạo ra bản dịch chính xác và tự nhiên trong ngôn ngữ mục tiêu.

Phía nguồn là văn bản được đánh dấu thực thể (nếu có) và thêm hướng dẫn dịch máy, trong khi phía mục tiêu giữ nguyên không đổi.

Ví dụ:

Đầu vào: English Sentence: "I watched the TV series 'Breaking Bad' last week."

Đầu ra: Chinese Sentence: "我上周看了电视剧《绝命毒师》。"

3.3 Nhiệm vụ nhận diện chủ thể có tên (Named Entity Recognition)

NER là tác vụ xác định và phân loại các thực thể có tên trong văn bản, chẳng hạn như tên người, địa điểm, tổ chức, ngày tháng, v.v. Mục tiêu là giúp hệ thống hiểu rõ hơn về ngữ cảnh và ý nghĩa của các thực thể trong văn bản.

Trong NER, đầu vào là một câu văn, và đầu ra là các nhãn thực thể (entity tags) và các thực thể được tìm thấy trong câu đó. Các thực thể được đánh dấu bằng thẻ XML để giúp mô hình nhận biết và xử lý chúng trong quá trình dịch. Nếu có

nhiều thực thể, chúng sẽ được nối tiếp nhau theo thứ tự xuất hiện. Nếu không có thực thể nào, đầu ra sẽ là "None".

Ví dụ:

Đầu vào: Một câu hoặc đoạn văn bản chứa các thực thể có tên: "I visited Paris last week."

Đầu ra: Văn bản được đánh dấu với các thẻ NER để chỉ định loại thực thể: "I visited <LOC>Paris</LOC> last week."

3.4 Huấn luyện đa nhiệm (Multi-task Training)

Huấn luyện đa nhiệm là phương pháp huấn luyện mô hình trên nhiều tác vụ cùng một lúc, nhằm cải thiện hiệu suất tổng thể của mô hình.

Trong bài toán EA-MT, huấn luyện đa nhiệm có thể bao gồm các tác vụ như dịch máy, nhận dạng thực thể, và dịch máy nhận biết thực thể.

3.5 Mô hình ngôn ngữ mT5

mT5 là một mô hình NLP (Xử lý ngôn ngữ tự nhiên) đa ngôn ngữ loại Neural Network LM được phát triển bởi nhóm Google Research vào năm 2020, giới thiệu trong bài báo "mT5: A massively multilingual pre-trained text-to-text transformer". Đây là một bước tiến lớn trong việc xử lý các tác vụ NLP, với đặc điểm nổi bật là tất cả các bài toán NLP đều được biểu diễn dưới dạng bài toán chuyển đổi "text-to-text" giữa nhiều ngôn ngữ khác nhau.

Đây là một mô hình đa ngôn ngữ dựa trên kiến trúc transformer encoder-decoder được huấn luyện trên bộ dữ liệu multilingual C4 (mC4) bao gồm 101 ngôn ngữ. Mô hình sử dụng định dạng "Text-to-text" cho tất cả các tác vụ NLP, dùng mục tiêu huấn luyện *span corruption*, trong đó các đoạn token đầu vào bị thay thế bằng mask token, và mô hình được huấn luyện để phục hồi các token bị mask.

3.6 Thư viện xử lý ngôn ngữ tự nhiên Spacy

Spacy là một thư viện xử lý ngôn ngữ tự nhiên (NLP) hiện đại và hiệu quả, được thiết kế để hỗ trợ các tác vụ NLP như phân tích cú pháp, nhận dạng thực thể (Named Entity Recognition - NER), gán nhãn từ loại (Part-of-Speech Tagging), và nhiều tác vụ khác. Spacy cung cấp các mô hình ngôn ngữ được huấn luyện sẵn cho nhiều ngôn ngữ, giúp người dùng dễ dàng tích hợp vào các ứng dụng NLP mà không cần phải huấn luyện lại từ đầu.

3.7 Chuẩn bị dữ liệu

3.7.1 Lọc dữ liệu

Với các dữ liệu song ngữ, có một số vấn đề thường gặp gây ảnh hưởng tiêu cực đến hệ thống và mô hình học từ dữ liệu này:

- Một số dòng dữ liệu có câu nguồn và đích giống nhau thường là các câu đơn giản, không mang nhiều ý nghĩa hoặc giá trị ngữ nghĩa. Chúng không giúp mô hình học được các đặc trưng phức tạp của ngôn ngữ, mà còn có thể gây nhiễu trong quá trình huấn luyện, làm giảm khả năng tổng quát hóa của mô hình.
- Các ký tự không phải chữ cái có thể bị không khớp giữa văn bản nguồn và văn bản đích.
- Có một số văn bản nguồn có tỷ lệ ký tự không phải chữ cái chiếm quá nhiều.
- Nhiều câu tiếng Anh nhưng chỉ có thể dịch ra một câu trong ngôn ngữ khác.
- Một câu văn bản nguồn có thể chứa nhiều ngôn ngữ hơn chỉ tiếng Anh.
- Một câu tiếng Anh nhưng có thể dịch ra nhiều nghĩa khác nhau trong ngôn ngữ khác.
- Có thể có thể thực thể được gán nhãn không khớp giữa văn bản nguồn với văn bản đích.

Đây là một số bước để giải quyết các vấn đề trên mà nhóm đã áp dụng:

- Bước 1: Loại bỏ các câu xuất hiện nhiều lần trong bộ dữ liệu và các câu có văn bản nguồn và văn bản đích giống nhau.
- Bước 2: Loại bỏ các cặp câu lặp lại khi một văn bản nguồn được liên kết với nhiều văn bản đích khác nhau hoặc ngược lại, thường ít nhất tỉ lệ là 1 câu nguồn : 3 câu đích và ngược lại.
- Bước 3: Lọc các câu không chứa nhiều ký tự chữ cái (các câu có ký tự chữ cái chiếm từ 50% trở lên).
- Bước 4: Lọc các câu lặp từ quá nhiều lần (các câu có số lượng từ không lặp lại lần nào ít hơn một nửa tổng số từ trong câu).
- Bước 5: Lọc các câu không đúng ngôn ngữ (sử dụng thư viện *langdetect* để phát hiện ngôn ngữ của câu và kiểm tra có khớp với ngôn ngữ của văn bản nguồn và văn bản đích hay không).
- Bước 6: Chuẩn hoá dấu câu (sử dụng thư viện *sacremoses* để chuẩn hoá cho tất cả các câu).

3.7.2 Gán nhãn thực thể có tên (Named-entity Tagging)

Nhóm sử dụng thư viện Spacy để thêm các thẻ thực thể có tên (NE tags) vào phía nguồn (source side) của dữ liệu huấn luyện cho tác vụ dịch máy nhận diện thực thể (EA-MT) và phía mục tiêu (target side) của dữ liệu cho tác vụ Nhận dạng thực thể (NER), còn ở tập dữ liệu cho tác vụ dịch máy (MT) được giữ nguyên. Spacy được chọn chủ yếu vì sự cân bằng tốt giữa độ chính xác trong việc gán thẻ, tốc độ xử lý và tính dễ sử dụng.

Đối với tác vụ NER, đầu vào là một đoạn văn bản tiếng Anh có chứa thực thể có tên và đầu ra là đoạn văn bản tiếng Anh được đánh dấu với thẻ NE để chỉ định loại thực thể. Đây là tác vụ duy nhất cần cả dữ liệu đầu vào và đầu ra là tiếng Anh.

3.7.3 Định dạng hướng dẫn (Instruction Formatting)

Tất cả các mô hình T5 đều được huấn luyện sẵn với một tập lệnh (instructions) gốc, cho phép chúng thực hiện các tác vụ chung như dịch máy, tóm tắt văn bản, và trả lời câu hỏi. Tuy nhiên, riêng với mT5, mô hình chỉ dừng lại ở việc xử lý các mask token (các token bị che) và chưa được huấn luyện sẵn với các lệnh cụ thể. Do đó, để sử dụng mT5 cho các tác vụ cụ thể, chúng ta cần tự huấn luyện thêm các lệnh phù hợp.

Một điểm chung của các mô hình T5 và mT5 là chúng đều yêu cầu có lệnh (instruction) phía trước dữ liệu đầu vào để hiểu và thực hiện nhiệm vụ. Ví dụ, nếu muốn mô hình dịch một câu từ tiếng Anh sang tiếng Pháp, chúng ta cần thêm lệnh như "Translate English to French:" trước câu cần dịch. Nếu không có lệnh này, mô hình sẽ không biết phải làm gì với dữ liệu đầu vào và có thể đưa ra kết quả không chính xác.

Việc thêm lệnh vào đầu vào giúp mô hình xác định rõ nhiệm vụ cần thực hiện, từ đó cải thiện độ chính xác và hiệu suất của mô hình. Đối với mT5, do chưa được huấn luyện sẵn các lệnh, ta cần tự xây dựng và huấn luyện các lệnh phù hợp với từng tác vụ cụ thể, chẳng hạn như dịch máy, nhận dạng thực thể (NER), hoặc dịch máy nhận biết thực thể (EA-MT). Quá trình này đòi hỏi việc chuẩn bị dữ liệu huấn luyện có chứa các lệnh và kết quả mong đợi, sau đó tinh chỉnh mô hình để nó học cách hiểu và thực hiện các lệnh này một cách chính xác.

3.8 Đánh giá mô hình

3.8.1 Thang đo BLEU

BLEU (Bilingual Evaluation Understudy) là một thang đo phổ biến để đánh giá chất lượng của bản dịch máy, đặc biệt là trong các nhiệm vụ dịch máy (MT) và dịch máy nhận biết thực thể (EAMT).

BLEU đánh giá việc dịch một câu thông qua việc so khớp câu đó với các câu mẫu trong thang điểm từ 0 (sai lệch tuyệt đối) đến 1 (khớp tuyệt đối). Cách tính của BLEU là đếm từ số n-gram

khớp nhau giữa câu mẫu (R) và câu được đánh giá (C), sau đó chia cho số token của C.

3.8.2 Evaluation metrics của cuộc thi

Thang đo đánh giá mô hình của cuộc thi bao gồm 2 thành phần chính: COMET và M-ETA.

COMET: Là thước đo đánh giá chất lượng của hệ thống dịch máy, dựa trên việc so sánh bản dịch của hệ thống với bản dịch của con người bằng mô hình huấn luyện trước.

Thành phần chính của COMET

- **Input:**
 - *Source sentence (Câu nguồn):* Văn bản ban đầu.
 - *Prediction sentence (Câu dự đoán):* Văn bản được dịch bởi mô hình.
 - *Reference sentence (Câu tham chiếu):* Văn bản dịch chuẩn.
- **Output:** Điểm số (*COMET score*) là giá trị liên tục thể hiện mức độ giống nhau giữa bản dịch dự đoán và bản dịch tham chiếu, có cân nhắc ngữ cảnh từ câu nguồn.

Hoạt động của COMET Mô hình COMET dựa trên kiến trúc của Transformer và sử dụng mô hình như XLM-RoBERTa đã được huấn luyện trước. Quá trình hoạt động gồm các bước:

1. **Mã hóa ngữ cảnh:** XLM-RoBERTa mã hóa đồng thời câu nguồn, câu dự đoán, và câu tham chiếu để tạo ra các vector biểu diễn ngữ nghĩa.
2. **So sánh các vector:** Vector câu dự đoán được so sánh với vector câu tham chiếu để đánh giá độ tương đồng. Các vector từ câu nguồn giúp mô hình hiểu ngữ cảnh và phát hiện lỗi dịch liên quan đến nội dung gốc.
3. **Tính điểm:** Mô hình tạo ra *COMET score*, một giá trị chuẩn hóa (thường trong khoảng từ -1 đến 1, nhưng có thể lớn hơn tùy dữ liệu), biểu thị chất lượng bản dịch.

M-ETA: Là thước đo đánh giá chất lượng của hệ thống trích xuất thực thể, dựa trên việc so sánh các thực thể được hệ thống trích xuất với các thực thể trong dữ liệu gốc đã được chú giải.

Thành phần chính của M-ETA

- **Input:**
 - *Gold Entities (Thực thể gốc):* Tập các thực thể trong dữ liệu được chú giải bởi con người.
 - *Predicted Entities (Thực thể dự đoán):* Tập các thực thể được trích xuất bởi mô hình.
 - *Matching Criteria (Tiêu chí khớp):* Quy tắc so khớp giữa thực thể gốc và thực thể dự đoán (ví dụ: khớp chính xác hoặc khớp một phần).
- **Output:** *M-ETA Score* là giá trị thể hiện tỷ lệ thực thể dự đoán đúng so với tổng số thực thể trong dữ liệu gốc. Giá trị này nằm trong khoảng từ 0 đến 1, với 1 biểu thị mô hình đạt hiệu quả tối đa.

Hoạt động của M-ETA

1. **So sánh thực thể gốc và thực thể dự đoán:** Mỗi thực thể gốc được kiểm tra xem có khớp với bất kỳ thực thể dự đoán nào hay không. Khớp có thể được định nghĩa theo các tiêu chí như khớp chính xác (*Exact Match*) hoặc khớp một phần (*Partial Match*).
2. **Tính số lượng thực thể khớp:** Đếm số thực thể gốc có ít nhất một thực thể dự đoán khớp.
3. **Tính M-ETA Score:** Tính điểm cuối cùng để đánh giá tỷ lệ thực thể dự đoán đúng.

$$\text{M-ETA Score} = \frac{\text{Số thực thể khớp}}{\text{Tổng số thực thể gốc}}$$

Tính điểm cuối cùng Điểm số được tính bằng trung bình điều hòa của hai thước đo:

$$\text{Final Score} = 2 \times \frac{\text{COMET} \times \text{M-ETA}}{\text{COMET} + \text{M-ETA}}$$

Giá trị điểm cuối cùng là sự tổng hợp của hai chỉ số này, đảm bảo phản ánh hiệu quả toàn diện của hệ thống.

4 Cài đặt thí nghiệm

4.1 Thực nghiệm

Việc thực nghiệm nhằm kiểm thử độ hiệu quả của mô hình **mT5** trên bộ dữ liệu được cung cấp từ cuộc thi và đánh giá khả năng áp dụng của mô hình đối với các ngôn ngữ khác nhau. Đây là một bước quan trọng để hiểu rõ hơn về khả năng tổng quát hóa và xử lý đa ngôn ngữ của mô hình **mT5** trong các tác vụ xử lý ngôn ngữ tự nhiên.

Dữ liệu sử dụng trong thực nghiệm là bộ dữ liệu được cung cấp bởi cuộc thi, bao gồm các văn bản đa ngôn ngữ phục vụ cho các tác vụ như phân loại văn bản, tóm tắt hoặc dịch máy. Mô hình được cài đặt bằng ngôn ngữ lập trình **Python**.

4.2 Nền tảng thực nghiệm

Nền tảng thực nghiệm mà nhóm thực hiện sử dụng là môi trường cài đặt local trên **VSCode**, kết hợp với **GPU** để tăng tốc quá trình huấn luyện. Sử dụng **GPU** giúp cải thiện đáng kể hiệu suất xử lý, đặc biệt khi làm việc với các mô hình lớn như **mT5**. **VSCode** cung cấp giao diện trực quan và tích hợp các công cụ hữu ích, giúp nhóm thực hiện triển khai và thử nghiệm mô hình một cách hiệu quả.

4.3 Phân tích và tiền xử lý dữ liệu

Đối với bước phân tích dữ liệu và tiền xử lý dữ liệu, nhóm thực hiện sử dụng các thư viện **langdetect**, **sacremoses**, và **spaCy**:

- **langdetect**: giúp phát hiện ngôn ngữ của văn bản, từ đó lọc và phân loại các văn bản theo ngôn ngữ mục tiêu.
- **sacremoses**: hỗ trợ chuẩn hóa văn bản, đặc

biệt là các tác vụ tokenization và detokenization cho các ngôn ngữ tự nhiên.

- **spaCy**: được sử dụng để xử lý ngôn ngữ tự nhiên (NLP), bao gồm tokenization, phân tích cú pháp, và nhận diện thực thể (NER), giúp tạo dữ liệu đầu vào chất lượng cho mô hình.

4.4 Cài đặt mô hình

Mô hình **mT5** được cài đặt và huấn luyện bằng **PyTorch** kết hợp với thư viện **Transformers** từ Hugging Face. **PyTorch** hỗ trợ tính toán tensor trên GPU, tối ưu hiệu suất tính toán và giảm thời gian huấn luyện. **Transformers** cung cấp các công cụ tiện ích để tải và sử dụng mô hình **mT5**, hỗ trợ nhóm thực hiện triển khai mô hình dễ dàng hơn.

4.5 Chia bộ dữ liệu

Bộ dữ liệu thực nghiệm được chia sẵn thành 3 phần lần lượt là **train**, **valid**, và **test**:

- Tập **train**: dùng để huấn luyện mô hình.
- Tập **valid**: dùng để tinh chỉnh tham số, đánh giá và lựa chọn mô hình tối ưu.
- Tập **test**: dùng để đánh giá độ chính xác và hiệu quả của mô hình đã được huấn luyện.

4.6 Kết luận

Thực nghiệm này sẽ giúp nhóm thực hiện đánh giá một cách toàn diện hiệu quả của mô hình **mT5** trên bộ dữ liệu của cuộc thi, đồng thời kiểm tra khả năng áp dụng của mô hình đối với các ngôn ngữ khác nhau.

5 Kết quả thí nghiệm

epoch	eval_loss	eval_bleu	eval_runtime	eval_samples_per_sec	eval_steps_per_sec
1.0	0.08026583492755890	59.53	2278.0991	8.403	2.101
2.0	0.06661463528871536	63.56	2218.2051	8.629	2.158
3.0	0.05985511094331741	65.90	2271.1957	8.428	2.107
4.0	0.05628131330013275	67.16	2224.5656	8.605	2.151
5.0	0.05505940690636635	67.93	2207.8513	8.670	2.168

Table 1: Kết quả từng epoch

Language	M-ETA	COMET	Final Score
ar_AE	0.00	67.13	0.00
de_DE	4.10	67.68	7.74
es_ES	6.50	75.32	11.96
fr_FR	4.83	68.96	9.04
it_IT	3.15	70.87	6.03
ja_JP	1.66	74.83	3.25
Average	3.37	70.80	6.34

Table 2: Kết quả trên tập evaluation

Để đánh giá quá trình thử nghiệm mô hình, nhóm chúng em đã sử dụng thang đo BLEU để đánh giá mô hình sau mỗi epoch (Table 1), và sau đó mang mô hình cuối cùng thử nghiệm trên tập evaluation để đánh giá theo thang đo của cuộc thi là M-ETA và COMET cùng với Final Score do cuộc

thi quy định (Table 2).

Từ kết quả ở Table 2, nhóm đưa ra kết luận rằng mô hình chạy tốt hơn trên các ngôn ngữ sử dụng kiểu chữ Latin hơn các ngôn ngữ có ký tự tượng hình như tiếng Trung, tiếng Hàn hay tiếng Ả Rập.

References

- [1] Simone Conia, Daniel Lee, Min Li, Umar Farooq Minhas, Saloni Potdar, and Yunyao Li. 2024. [Towards cross-cultural machine translation with retrieval-augmented generation from multilingual knowledge graphs](#). In *Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing*, pages 16343–16360, Miami, Florida, USA. Association for Computational Linguistics.
- [2] Ricardo Rei, Craig Stewart, Ana C Farinha, and Alon Lavie. 2020. [Comet: A neural framework for mt evaluation](#).

- [3] Matiss Rikters and Makoto Miwa. 2024. [Entity-aware multi-task training helps rare word machine translation](#). In *Proceedings of the 17th International Natural Language Generation Conference*, pages 47–54, Tokyo, Japan. Association for Computational Linguistics.
- [4] Priyanka Sen, Alham Fikri Aji, and Amir Saffari. 2022. [Mintaka: A complex, natural, and multilingual dataset for end-to-end question answering](#).
- [5] Radhika Sharma, Pragya Katyayan, and Nisheeth Joshi. 2023. [Improving the quality of neural machine translation through proper translation of name entities](#). In *2023 6th International Conference on Information Systems and Computer Networks (ISCON)*, page 1–4. IEEE.
- [6] Linting Xue, Noah Constant, Adam Roberts, Mihir Kale, Rami Al-Rfou, Aditya Siddhant, Aditya Barua, and Colin Raffel. 2021. [mt5: A massively multilingual pre-trained text-to-text transformer](#).